

对抗影子价格的有效支持地板

The Effective-Support Floor of the Adversarial Shadow Price:
An $\Omega(\sqrt{k_\varepsilon})$ Lower Bound

王广宇

billgywang@gmail.com

摘要 对抗鲁棒性是一维、有价的资源。本文把对抗半径 ε 视为约束极值价值函数 $L^*(\mathcal{E})$ 的一维预算，将鲁棒边际价定义为其次梯度 $\lambda_\varepsilon = \partial L^*/\partial \varepsilon$ 。主结果是对这一价格的地板，其正确定价量是鲁棒最优判别的有效支持 $k_\varepsilon := (\|w^*\|_1/\|w^*\|_2)^2$ （软阈值 active 支持的 participation ratio）：在近阈值工作点下 $\lambda_\varepsilon \geq c_M \sqrt{k_\varepsilon}/\sigma$ ，几何来源是 ℓ_∞ 对手与 ℓ_1 对偶。该 k_ε -地板在高斯-线性体制下无条件成立（定理 4.1），并对全体对称对数凹噪声分布无关地成立（定理 5.5）；它以 w^* 自身的有效支持定价，本身并非维数界。其维数特化则是有条件的：稠密情形 $k_\varepsilon = \Theta(d)$ （给出 $\Omega(\sqrt{d})$ ）在一个可检验的 delocalization 条件下成立（命题 5.6，高斯下无条件），稀疏情形在支撑 delocalization 下给出 $\Omega(\sqrt{k})$ ，稳定秩情形 $k_\varepsilon = \Theta(r_{\text{eff}})$ （ $r_{\text{eff}} = \text{tr}(\Sigma)/\|\Sigma\|$ ，给出 $\Omega(\sqrt{r_{\text{eff}}})$ ）在对齐有效占据下成立（命题 6.3，conditional）。比例渐近锐常数由凸高斯极小极大定理（CGMT）给出（命题 5.1，literature-derived），且该地板经 ℓ_∞ 二次型曲率 κ_∞ 推广到任意 C^2 分类器的局部工作点（命题 7.1）。合成实验证实 $\sqrt{k_\varepsilon}$ 是稠密、稀疏、低有效秩三体制下的普适定价量，并证实稳定秩特化的条件确属必要。

关键词： 对抗鲁棒性；影子价格；有效支持 $\sqrt{k_\varepsilon}$ ； ℓ_∞/ℓ_1 对偶几何；稳定秩；凸高斯极小极大定理（CGMT）。

Keywords: adversarial robustness; shadow price; effective support; ℓ_∞/ℓ_1 duality geometry; stable rank; convex Gaussian min-max theorem.

1 引论

大模型的成本重心正在迁移。过去它几乎等同于一次性的预训练算力；而随着能力越来越多地来自推理侧——更长的上下文窗口、更长的推理链、多步智能体工作流、多模态对齐——算力从“训练时一次性投入”转为“推理时反复发生、且随交互持续累积”的开销。与之并生的另一维成本，是随部署环境对抗性上升而日益醒目的鲁棒资源：为了让模型在半径 ε 内对输入扰动保持行为一致，需要付出可观的训练/认证代价。因此，“多投一份资源是否值得”从训练前的一次分配，变成一个跨训练、推理、鲁棒的持续定价问题；而其中最难量化、也最容易被工程直觉低估的一维，正是鲁棒预算。

本文聚焦这一维。我们要问的问题很具体：作为价值函数的次梯度，鲁棒边际价 $\lambda_\varepsilon = \partial L^*/\partial \varepsilon$ 的大小从何而来？它是否随维数 d 增长？何时可以被表示的内在维数替代？答案不平凡：高维深度模型中，即使采用最优判别，一份对抗半径的边际成本也不能任意压小——存在一个由 ℓ_∞ 对

手与 ℓ_1 对偶几何强制的有效支持地板；当鲁棒最优方向在 d 维上稠密展开时，它退化为 $\Omega(\sqrt{d})$ 。这是高维模型“经济上难以鲁棒”最本质的一个来源。

本文的贡献 是把这条地板做严格并给出它的正确定价单元。

- (i) 我们把资源受限的学习写成价值函数 $L^*(\mathcal{E})$ ，其对预算的次梯度即影子价格 $\lambda = -\partial L^*/\partial \mathcal{E}$ ；对抗半径 ε 作为一维预算，其价格 $\lambda_\varepsilon \in \partial_\varepsilon L^*$ ，见 § 2。
- (ii) 我们建立读出算子（readout operator） Π_Y 的结构性质：鲁棒边际价、训练侧协态、静态预算梯度，是同一 ∂L^* 沿不同预算坐标的读出；并给出一座局部桥（命题 8.1, $\varepsilon \rightarrow 0$ ）把鲁棒价与训练侧输入梯度联系起来。
- (iii) § 2 给出鲁棒价所在的非光滑基础：Rademacher 定理保证价格几乎处处单值、临界处退化为 Danskin 区间。
- (iv) § 4 是全文核心。定理 4.1 证明鲁棒边际价的正确定价量是有效支持 k_ε （软阈值 active 支持 $(|\mu| - \varepsilon)_+$ 的 participation ratio）——在近阈值（margin-density）工作点下 $\lambda_\varepsilon \geq c\sqrt{k_\varepsilon}/\sigma$ ；稠密信号使 $k_\varepsilon = \Theta(d)$ 、得 $\Omega(\sqrt{d})$ 特例（population 绝对常数；有限样本的比例渐近锐常数由 CGMT 给出，命题 5.1）。命题 6.3 把 k_ε 换为稳定秩 $r_{\text{eff}} = \text{tr}(\Sigma)/\|\Sigma\|$ ，在有效占据条件下给出 $\lambda_\varepsilon \geq c\sqrt{r_{\text{eff}}}/\sqrt{\|\Sigma\|}$ （conditional）；自适应特征学习版本是本文明确保留的开放问题。

须强调贯穿全文的一个区分： k_ε 是判别器权重空间的几何量，而 $r_{\text{eff}} = \text{tr}(\Sigma)/\|\Sigma\|$ 是数据协方差空间的几何量。在信号-噪声共支撑下二者等价——权重空间的有效支持坍缩到数据空间的稳定秩——这正是命题 6.3 所精确刻画的。

主要机制（Main Mechanism）。 ℓ_∞ 对抗 $\Rightarrow$ 逐坐标边际收缩 $-\varepsilon\|w\|_1 \Rightarrow$

$$\lambda_\varepsilon = \frac{\|w^*\|_1}{\sigma\|w^*\|_2} \phi(t(\varepsilon)) = \frac{\sqrt{k_\varepsilon}}{\sigma} \phi(t(\varepsilon)), \quad |t| \leq M \Rightarrow \lambda_\varepsilon \geq c_M \frac{\sqrt{k_\varepsilon}}{\sigma}.$$

即对抗定价的操作维数是有效支持 k_ε ，环境维数 d 只是其稠密特例； $\sqrt{k_\varepsilon}$ 是贯穿全文（定理 4.1、推论 4.4、命题 6.3）的统一定价量。

主张状态 表 1 汇总各结果的状态与关键假设。我们用 Established 表示自足证明，Literature-derived conditional 表示援引已发表 CGMT 刻画并特化所得，Conditional 表示依赖显式假设，Conjectural 表示开放问题。

全文结构 § 2 建立对抗影子价格的形式基础：价值函数、 ε 作为（收紧型）对抗预算、KKT/包络、读出算子与非光滑基础。§ 3 给出 ℓ_∞/ℓ_1 几何与闭式鲁棒风险（引理 3.1）。§ 4 建立 population 有效支持地板（定理 4.1），含稠密、稀疏特例。有限样本锐常数（CGMT）、有效秩修正、局部深网推广、蕴含与合成验证、相关工作及结论构成其余各节。

结果	内容	关键假设	状态
引理 3.1	ℓ_∞/ℓ_1 闭式鲁棒风险与价格	高斯噪声 $z \sim N(0, \sigma^2 I)$ 、线性判别、二分类	Established
定理 4.1	有效支持地板 $\lambda_\varepsilon \geq c_M \sqrt{k_\varepsilon}/\sigma$	高斯线性; 近阈值 margin-density $ t \leq M$	Established
定理 5.5	同一 k_ε -地板, 分布无关 (非 $\sqrt{d}$ 界)	对称对数凹噪声 + margin-density/工作 CDF 水平 $\geq \alpha_0$	Established
推论 4.4	稀疏 $\sqrt{k}$ 下界	定理 4.1 + k -稀疏 μ (active participation $\Theta(k)$)	Established
命题 5.1	比例渐近锐常数 (CGMT)	高斯混合、 $m/d \rightarrow \kappa$ 、凸替代 +ridge	Literature-derived cond.
命题 6.3	有效占据下 $k_\varepsilon = \Theta(r_{\text{eff}})$	(EO0)-(EO4): 基对齐、平谱、信号尾控、有效信号 delocalized、次梯度尾控; 非自适应	Conditional
命题 7.1	局部深网一阶敏感度	C^2 分类器、工作点、一阶邻域、 κ_∞ 余项	Established

Table 1: 核心结果的状态与关键假设（完整表随有限样本与有效秩两节给出）。

2 对抗影子价格

2.1 资源约束下的学习

我们把资源受限的学习问题写成一个约束极值价值函数。设 X 为资源-控制空间（含训练控制子空间、若干静态预算轴，以及对抗半径轴）， $L^*: X \rightarrow \mathbb{R}$ 为价值函数

$$L^*(\mathcal{E}) = \min_{x \in X} \{ L(x) : g_i(x) \leq \mathcal{E}_i, i = 1, \dots, d \},$$

其中 L 为损失、 g_i 为资源约束、 $\mathcal{E} = (\mathcal{E}_1, \dots, \mathcal{E}_d)$ 为预算。对抗半径 ε 是其中之一，以收紧型约束进入： ε 越大，可行集越小、 L^* 越高。

2.2 变分原理

在标准正则性下，我们得到乘子，其一坐标即对抗预算的影子价格。

定理 2.1 (d 维资源变分原理; 乘子的存在唯一性). 设 (A1) 凸性 (X 凸, L 及各 g_i 凸且 C^1 , 至少在最优点附近) 与 (A2) 约束品性 (Slater 或 MFCQ)。则最优配置 $x^*(\mathcal{E})$ 满足 KKT 平稳性条件: 存在乘子 $\lambda = (\lambda_1, \dots, \lambda_d) \geq 0$ (一般不唯一), 使

$$\nabla L(x^*) + \sum_i \lambda_i \nabla g_i(x^*) = 0, \quad \lambda_i (g_i(x^*) - \mathcal{E}_i) = 0, \quad i = 1, \dots, d.$$

若再设 (A3) LICQ (active 约束梯度 $\{\nabla g_i(x^*) : g_i(x^*) = \mathcal{E}_i\}$ 线性无关) 或 (A3') 严格互补加二阶充分条件, 则 λ 唯一。凡本文需价格单值处 (§ 4 的 λ_ε 表达式与 ε^{**} 一阶条件), 我们限于 L^* 可微的邻域; 由命题 2.2 这等价于要求 λ 在该处唯一, 且由 Rademacher 定理对 Lebesgue-几乎所有 ε 成立。

互补松弛条件有直接的经济读法：只有被充分使用的资源才带正价——未达预算的资源在实际上是免费的。

2.3 影子价格即价值函数的（次）梯度

命题 2.2 (影子价格即价值函数的（次）梯度). 在定理 2.1 的假设下：(a) 在可微点（等价地，乘子唯一处，由 (A3) 或 (A3')）有严格包络恒等式 $\lambda_i = -\partial L^*/\partial \varepsilon_i$ ；(b) 一般而言 L^* 局部 Lipschitz、但未必处处可微， $-\lambda$ 属于 Clarke 次微分 $\partial_\varepsilon L^*$ 。特别地，对抗价 λ_ε 恰在 L^* 沿 ε 方向可微处单值；在临界集上退化为 Danskin 区间。

于是梯度 ∇L^* 自然分裂为方向（哪个预算最值得放松）与大小（每单位预算之价）。下面的读出算子沿不同坐标读取同一梯度。

推论 2.3 (边际相等). 在最优点、且总预算 $\sum_i \varepsilon_i \leq B$ 下，重新分配预算会使各 active 维度上每单位预算购得的边际损失下降相等。这是价值函数最优点处的经典包络条件。

2.4 读出算子

影子价格是单一对象 ∂L^* ，沿不同预算坐标读取：训练坐标给出 Pontryagin 协态，静态坐标为普通梯度，对抗半径坐标为 Clarke 次微分——同一对象的三种读出，而非三套理论。我们只用到两点：§ 4 的地板是沿 ε 的读出（与所取读法无关）；且 $\varepsilon \rightarrow 0$ 时鲁棒价被训练侧梯度对偶范数 $\mathbb{E}\|\nabla_x \ell\|_*$ 廉价估计（命题 8.1）。读出算子 Π_Y 的形式定义与“两种读出”恒等式移至附录 A.4。

2.5 非光滑基础

上文的测度论表述（几乎处处单值、临界集上 Danskin 区间）需非光滑工具。对局部 Lipschitz 的 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，Clarke 次微分 $\partial f(x) = \text{conv}\{\lim \nabla f(x_k) : x_k \rightarrow x\}$ （邻近梯度极限的凸包）在 f 凸时与凸次微分一致；鲁棒边际价本身是 $\lambda_\varepsilon \in \partial_\varepsilon L^*(\mathcal{E})$ ，而等式 $\lambda_\varepsilon = \partial L^*/\partial \varepsilon$ 仅在可微点成立。由 Rademacher 定理（局部 Lipschitz 函数 Lebesgue-几乎处处可微），对几乎所有 ε ， $\partial_\varepsilon L^* = \{\lambda_\varepsilon\}$ 为单点、价格是良定的经典导数；非光滑性被限于 Lebesgue-零测集。

3 ℓ_∞/ℓ_1 几何

现特化到证明地板的设定。取标准二分类模型 $x = y\mu + z$ ，标签 $y \in \{\pm 1\}$ 等概、噪声 $z \sim N(0, \sigma^2 I_d)$ ，线性判别 $x \mapsto \text{sign}\langle w, x \rangle$ 。对 ℓ_∞ -有界对手 $\|\delta\|_\infty \leq \varepsilon$ ，最坏扰动把边际恰减少 $\varepsilon\|w\|_1$ ——这是 ℓ_∞ 攻击的标志，也是 ℓ_1 对偶几何之源。

引理 3.1 (闭式鲁棒风险与价格). 对上述模型与线性判别 w ，鲁棒 (ℓ_∞ -半径 ε) 误分类风险为

$$R(\varepsilon; w) = \Phi(t(w)), \quad t(w) := \frac{\varepsilon\|w\|_1 - \langle w, \mu \rangle}{\sigma\|w\|_2},$$

它关于 ε 单调递增。其边际价为

$$\lambda_\varepsilon(w) = \frac{\partial R}{\partial \varepsilon} = \frac{\|w\|_1}{\sigma \|w\|_2} \phi(t(\varepsilon)) = \frac{\sqrt{k_\varepsilon(w)}}{\sigma} \phi(t(\varepsilon)), \quad k_\varepsilon(w) := \left(\frac{\|w\|_1}{\|w\|_2} \right)^2,$$

其中 $\phi = \Phi'$ 为标准正态密度、在标准化边际 $t(\varepsilon)$ 处取值。（证明见附录 B.1。）

故即便在固定判别层面，价格已分解为纯几何量 $\sqrt{k_\varepsilon(w)} = \|w\|_1 / \|w\|_2$ （ w 的 participation ratio 之平方根）与密度因子 $\phi(t(\varepsilon))$ （度量分类器离决策阈值多近）。

4 Population 有效支持地板

核心结果为鲁棒最优判别 $w^*(\varepsilon)$ ——被认证的工作点——定价：其边际价被其自身的有效支持从下界住， $\lambda_\varepsilon \geq c_M \sqrt{k_\varepsilon} / \sigma$ 。（这是关于被定价工作点的陈述，而非对所有判别取的 minimax。）

定理 4.1 (对抗影子价格的有效支持地板；population，带 margin-density 条件). 考虑标准设定 $x = y\mu + z$ 、 $z \sim N(0, \sigma^2 I_d)$ ，设 $w^*(\varepsilon)$ 为鲁棒最优线性判别。假设：(非退化) $\varepsilon < \varepsilon_{\text{active}} := \max_i |\mu_i|$ ，使 active 支持 $S_\varepsilon = \{i : |\mu_i| > \varepsilon\}$ 非空、 $(|\mu| - \varepsilon)_+ \neq 0$ 、 k_ε 良定；(margin-density) 标准化工作边际满足 $|t(\varepsilon)| \leq M$ （常数 M ）。则

$$\lambda_\varepsilon = \frac{\|w^*\|_1}{\sigma \|w^*\|_2} \phi(t(\varepsilon)) \geq c_M \frac{\sqrt{k_\varepsilon}}{\sigma}, \quad c_M = \phi(M), \quad k_\varepsilon = \left(\frac{\|w^*\|_1}{\|w^*\|_2} \right)^2,$$

常数 c_M 仅依赖 M （从而仅依赖信噪比 ρ ），既不含样本量、也不含比例渐近比；比例渐近锐常数见命题 5.1。对 delocalized 稠密信号， $k_\varepsilon = \Theta(d)$ 、下界回收 $\Omega(\sqrt{d})$ 特例。当 $\varepsilon \uparrow \varepsilon_{\text{active}}$ ，active 支持收缩至最大坐标、鲁棒 Bayes 优势消失， $\sup_w [\frac{1}{2} - R(\varepsilon; w)] \rightarrow 0$ ；软阈值极小元退化（ $w^* \rightarrow 0$ 作为极限、不可达—— $w = 0$ 不是合法判别， $\text{sign}\langle 0, x \rangle$ 无定义），故对 $\varepsilon \geq \varepsilon_{\text{active}}$ 不主张地板，与注 4.3 的双阈值图景一致。（证明见附录 B.2。）

k_ε 从何而来：三步 soft-threshold 推导 k_ε 的定义并非外加，而是 KKT/软阈值结构的直接结果（完整论证见附录 B.2）。

(1) 由 Φ 单调，极小化鲁棒风险 $R(\varepsilon; w) = \Phi(t(w))$ 等价于在 $\|w\|_2 = 1$ 下极小化 $\varepsilon \|w\|_1 - \langle w, \mu \rangle$ 。

(2) 对齐符号（令 $u_i = \text{sign}(\mu_i) w_i$ ，使最优处 $u \geq 0$ ），问题化为球-正卦限线性规划

$$\max_{\|u\|_2=1, u \geq 0} \sum_i (|\mu_i| - \varepsilon) u_i.$$

(3) 该线性泛函的最优方向为系数向量之正部， $u \propto (|\mu| - \varepsilon)_+$ ，即 $w_i^* \propto \text{sign}(\mu_i)(|\mu_i| - \varepsilon)_+$ 。

于是有效支持 $k_\varepsilon = (\|w^*\|_1 / \|w^*\|_2)^2$ 是软阈值解的 participation ratio：它是 KKT/软阈值产生的量、而非外部定义。这一步把 $\sqrt{k_\varepsilon}$ 从猜测的定价量变为导出的定价量。阈值恰为 ε ，因为 ℓ_∞ 攻击项 $\varepsilon \|w\|_1 = \varepsilon \sum_i |w_i|$ 通过其次梯度 $\varepsilon \text{sign}(w_i)$ 与信号 μ_i 逐坐标竞争：坐标 i 保持 active 当且仅当 $|\mu_i| > \varepsilon$ 。

注 4.2 (margin-density 的操作含义). 窗口 $|t(\varepsilon)| \leq M$ 不是技术装置, 而是分类器工作在非平凡鲁棒-精度点的操作性陈述——即鲁棒确实要付代价的体制。窗口之外无需地板: (i) $t \rightarrow -\infty$ (即 $\varepsilon \rightarrow 0$ 、高置信/高信噪) 时分类器远离阈值、鲁棒精度 $\rightarrow 1$ 、边际成本随 $\phi(t) \rightarrow 0$ 衰减 (过自信分类器在边际上几乎不为额外鲁棒付费); (ii) $t \rightarrow +\infty$ (ε 越过认证半径 $\varepsilon_{\text{cert}}$) 时鲁棒精度 $\rightarrow 0$ 、线性判别不携带信息, 分析与地板皆不适用。 $\sqrt{k_\varepsilon}$ 律恰描述鲁棒有非平凡价格的那一体制。

注 4.3 (两个阈值: $\varepsilon_{\text{active}}$ 与 $\varepsilon_{\text{cert}}$). 支持窗口由 $\varepsilon_{\text{active}}$ 主导, 即 active 支持坍缩尺度 $\approx \max_i |\mu_i|$, 软阈值 $(|\mu| - \varepsilon)_+$ 在此开始丢失 $\Theta(d)$ 个 active 坐标。这是几何量, 概念上不同于认证半径 $\varepsilon_{\text{cert}} := \langle w^*, \mu \rangle / \|w^*\|_1$ ($R = \frac{1}{2}$ 之半径): 对 delocalized 稠密信号, 二者同阶 $\Theta(\|\mu\|_2 / \sqrt{d})$, 但一般不相等。

推论 4.4 (稀疏信号). 把定理 4.1 的假设 (i) 换为支撑于 k 个坐标的 k -稀疏均值 μ , 且其有效信号 $a_\varepsilon = (|\mu| - \varepsilon)_+$ 于支撑上 delocalized (participation ratio $\Theta(k)$; 尖峰 μ 反而给 $k_\varepsilon = O(1)$, 与引理 6.2 同一微妙)。则 $k_\varepsilon = \Theta(k)$ 、 $\lambda_\varepsilon \geq c_M \sqrt{k}/\sigma$ 。(证明见附录 B.4。)

5 有限样本与分布普适性

定理 4.1 的 population 地板带一个绝对常数。在比例渐近体制下, 锐常数由 CGMT 钉定; 而对固定判别, 高斯混合假设可放宽为亚高斯。

命题 5.1 (比例渐近锐常数: CGMT 刻画的一个条件推论). 把定理 4.1 的稠密设定置于归一化高斯混合 $x | y \sim N(y\mu, I_d)$ 、 $\|\mu\|_2 = 1$ (一般 σ 只是重标度)、 $\mu_i \stackrel{iid}{\sim} D$, 并取判别为 ridge 正则化的鲁棒 ERM

$$\hat{\theta}(\varepsilon) := \arg \min_{\theta} \sum_{i=1}^m L\left(y_i \langle x_i, \theta \rangle - \frac{\varepsilon_{\text{tr}}}{\sqrt{d}} \|\theta\|_1\right) + r \|\theta\|_2^2,$$

其中 L 凸且递减、 $r > 0$ (主定理半径经 $\varepsilon = \varepsilon_{\text{tr}}/\sqrt{d}$ 映射到其尺度, 故逐坐标阈值与信号尺度 $|\mu_i| = \Theta(1/\sqrt{d})$ 在 $\|\mu\|_2 = 1$ 下相匹配), 在比例体制 $m, d \rightarrow \infty$ 、 $\delta := m/d \rightarrow \kappa \in (0, \infty)$ 下考虑。设数据非 $(\ell_\infty, \varepsilon)$ -可分, 使得 Taheri, Pedarsani 与 Thrampoulidis (2022, ISIT, 定理 1, 式 7) 的八标量凸-凹鞍点问题——变量 $(\alpha, \tau_1, \omega, \nu, \tau_2, \beta, \gamma, \eta)$ (我们以 ω^* 记其标量序参量, 保留 w^* 表我们的鲁棒最优向量), 由 L 与 $|\cdot|$ (ℓ_∞ 攻击的 ℓ_1 对偶) 的 Moreau 包络构造——有唯一有界解, 其分量为 $(\omega^*, \nu^*, \alpha^*)$ 。则其引理 2 给出序参量极限

$$\varepsilon_{\text{tr}} \|\hat{\theta}\|_1 / \sqrt{d} \rightarrow \omega^*, \quad \|P_\mu \hat{\theta}\|_2 \rightarrow \nu^*, \quad \|P_\mu^\perp \hat{\theta}\|_2 \rightarrow \alpha^*, \quad \text{故 } \|\hat{\theta}\|_2 \rightarrow \sqrt{\nu^{*2} + \alpha^{*2}},$$

其中 P_μ 投影到 μ 。取比值得精确读出

$$\sqrt{k_\varepsilon(\hat{\theta})} = \frac{\|\hat{\theta}\|_1}{\|\hat{\theta}\|_2} = c(\kappa) \sqrt{d} + o(\sqrt{d}), \quad c(\kappa) = \frac{\omega^*}{\varepsilon_{\text{tr}} \sqrt{\nu^{*2} + \alpha^{*2}}} > 0,$$

故 $k_\varepsilon(\hat{\theta}) = c(\kappa)^2 d = \Theta(d)$ 。代入引理 3.1, 在 margin-density 窗口内比例渐近鲁棒价为 $\hat{\lambda}_\varepsilon = (c(\kappa) \sqrt{d}/\sigma) \phi(t)$, 把定理 4.1 的 population 常数 $c(\rho)$ 锐化为显式、依赖 κ 的 $c(\kappa)$ 。当 $\kappa \rightarrow \infty$ 时我们预期 $c(\kappa) \rightarrow c(\rho)$ (m 个损失项主导固定 ridge, 有效正则消失、鞍点形式上退化为无 ridge 的 population 最优); 严格极限需 $\kappa \rightarrow \infty$ 时对不动点的一致控制, 本文不作。这与其分析中 $\delta \rightarrow \infty$ 时对抗误差趋于 Bayes-鲁棒误差一致。(推导见附录 B.3。)

我们的对象	CGMT 序参量	来源
$\varepsilon_{\text{tr}} \ \hat{\theta}\ _1 / \sqrt{d}$	ω^* (标量 ℓ_1 序参量)	TPT22, 引理 2
$\ P_\mu \hat{\theta}\ _2$ (信号重叠)	ν^*	TPT22, 引理 2
$\ P_\mu^\perp \hat{\theta}\ _2$ (噪声分量)	α^*	TPT22, 引理 2
鞍点于 $(\alpha, \tau_1, \omega, \nu, \tau_2, \beta, \gamma, \eta)$	唯一不动点	TPT22, 定理 1, 式 7
读出 $\ \hat{\theta}\ _1 / \ \hat{\theta}\ _2 = c(\kappa) \sqrt{d}$	$c(\kappa) = \omega^* / (\varepsilon_{\text{tr}} \sqrt{\nu^{*2} + \alpha^{*2}})$	本文 (命题 5.1)

Table 2: 命题 5.1 的对应关系：我们所用每个对象都是已发表的 CGMT 序参量 (Taheri et al., 2022, ” TPT22”)；末行是我们读出的单一标量。我们不证新的 CGMT 结果。

这是一个显式外部定理的条件推论：它援引 Taheri et al. (2022) (各向同性) 与 Javanmard and Soltanolkotabi (2022) (各向异性) 的精确 CGMT 刻画，并读出单一标量 $\|\hat{\theta}\|_1 / \|\hat{\theta}\|_2$ ；我们不证任何新的 CGMT 结果。其有效性以非可分性与其不动点唯一性为条件。非高斯普适性问题即猜想 5.7。

注 5.2 (与所引 CGMT 结果的假设核对). 本命题不重建 CGMT 机器；它把我们的设定与两篇已发表的精确分析对齐并特化。(i) 数据模型：我们的二元高斯混合 $x = y\mu + z$, $z \sim N(0, \sigma^2 I)$, 是 Javanmard and Soltanolkotabi (2022) 一般各向异性混合与 Taheri et al. (2022) 相关特征混合的各向同性特例 (§ 6 的各向异性 Σ 落在前者内)。(ii) 扰动：我们的 ℓ_∞ 攻击被其 ℓ_p / ℓ_q ($p, q \geq 1$) 分析覆盖。(iii) 损失：我们的凸非增替代匹配其”适当递减凸损失” / 凸 ERM。(iv) 正则：我们的 ridge 被其对一般凸正则的推广覆盖，其强凸性给出 $\hat{\theta}$ 与不动点的唯一性。(v) 体制：比例渐近 $n/d \rightarrow \kappa$ 匹配。(vi) 读出：其刻画追踪一小组标量序参量 (含 $\|\hat{\theta}\|_2$ 、与 μ 的相关、以及 ℓ_∞ 对偶产生的 ℓ_1 -型量)；我们仅读出单一比值 $\|\hat{\theta}\|_1 / \|\hat{\theta}\|_2$ 并证其在稠密极限下的 $\sqrt{d}$ 尺度——此特化是我们的贡献，而非新的 CGMT 结果。

命题 5.3 (固定稠密判别下的亚高斯普适性). 固定判别 w 使 $\|w\|_\infty / \|w\|_2 = O(1/\sqrt{d})$ ，并设噪声坐标独立、零均值、亚高斯 (参数 $\tau^2 > 0$) 且另有有界密度或满足 Cramér 条件，使局部中心极限定理适用。则鲁棒边际价 $\lambda_\varepsilon(w) = \|w\|_1 p_S(\varepsilon \|w\|_1 - \langle w, \mu \rangle)$ 保留其 $\sqrt{d}$ 前因子，常数经 p_S 与 τ 进入。局部-CLT 假设是必要的：Berry-Esseen 只控制 CDF F_S ，而价格用到密度 p_S ，其收敛需 Gnedenko 型局部极限定理。(证明见附录 B.5。) Established (部分：固定判别)。

5.1 超越高斯：对称对数凹噪声的分布无关地板

定理 4.1 中的高斯假设只经密度因子 $\phi(t) \geq \phi(M)$ 进入。对数凹性免费提供同一下界，从而为核心地板去掉高斯假设。

引理 5.4 (对数凹密度地板). 设 g 为 $\mathbb{R}$ 上对称对数凹密度、方差 1、CDF 为 F 。则对每个水平 $\alpha_0 \in (0, \frac{1}{2}]$ ，存在与 g 无关的常数 $c(\alpha_0) > 0$ ，使当 $F(t) \geq \alpha_0$ 且 $t \leq 0$ 时 $g(t) \geq c(\alpha_0)$ ；显式取值 $c(\alpha_0) = \alpha_0/4$ 可行 (经 $g(0) = \|g\|_\infty \geq \frac{1}{8}$ 与 $g(t) \geq 2g(0)F(t)$)。于是若 z 有 iid 对称对数凹坐标 (方差 σ^2)，则对任意 w ，标准化投影 $\tilde{S} = \langle w, z \rangle / (\sigma \|w\|_2)$ 为对称对数凹、单位方差，且在 margin-density 工作点 (鲁棒精度 $F(t) \geq \alpha_0$) 其密度满足 $p_{\tilde{S}}(t) \geq c_M := c(\alpha_0)$ 。该界为绝对 (与噪声律无关)，且因系于工作 CDF 水平，无需支撑附注。(证明见附录 B.6。)

定理 5.5 (分布无关的有效支持地板；对称对数凹噪声). 设 z 有 iid 对称对数凹坐标、方差 σ^2 (高斯、Laplace、logistic、双曲正割、均匀, ...)。在 margin-density 窗口 $|t(w^*)| \leq M$ 内工作的鲁棒最优判别 $w^*(\varepsilon)$ 处,

$$\lambda_\varepsilon(w^*) = \frac{\sqrt{k_\varepsilon}}{\sigma} p_{\mathcal{S}^*}(t(w^*)) \geq c_M \frac{\sqrt{k_\varepsilon}}{\sigma},$$

其中 c_M 是引理 5.4 的绝对密度地板，在对称对数凹类内与噪声律无关。这把定理 4.1 的有效支持地板从高斯推广到全体对称对数凹噪声，不用 CLT、不用比例渐近极限。它是一个 k_ε -地板：以 w^* 自身的有效支持定价，本身不给出 $\Omega(\sqrt{d})$ ——维数陈述需命题 5.6 的 delocalization $k_\varepsilon = \Theta(d)$ 。(证明见附录 B.7。)

上述地板以 w^* 自身的 k_ε 定价。要回收稠密 $\Omega(\sqrt{d})$ 陈述，还须知 w^* 是 delocalized ($k_\varepsilon = \Theta(d)$)——与地板不同，这一点确实依赖分布 (argmin 未必等于高斯软阈值)。下一结果给出干净、可检验的充分条件。

命题 5.6 (分布无关的稠密地板；一个可检验的 delocalization 条件). 设有效信号 $a_\varepsilon = (|\mu| - \varepsilon)_+$ 、其稠密软阈值方向 $\hat{a}_\varepsilon = a_\varepsilon / \|a_\varepsilon\|_2$ 、participation 分数 $c := k_\varepsilon(a_\varepsilon)/d \in (0, 1]$ 、最优标准化边际 $t_d = -\|a_\varepsilon\|_2/\sigma = \min_w t(w)$ ，以及窗口边缘处的高斯密度 $\phi_M := \phi(M)$ (区别于引理 5.4 的对数凹地板 c_M)。定义标准化噪声和的最大高斯 CDF-欠射

$$\Delta_0 := \sup_{\|a\|_2=1} \sup_t [\Phi(t) - G_a(t)]_+, \quad G_a := \text{law}\left(\sum_i a_i \zeta_i\right).$$

直观上，localize w 买到更薄的左尾 (风险上至多 Δ_0) 却付出标准化边际代价 (每单位亏损值 ϕ_M)；只要边际代价占优，稠密软阈值即胜。若 $\Delta_0 < \frac{1}{2} c \phi_M |t_d|$ ，则鲁棒最优 w^* delocalized，且

$$k_\varepsilon(w^*) \geq c d \left(1 - \sqrt{\frac{2\Delta_0}{\phi_M |t_d|}}\right)^2 = \Theta(d), \quad \text{从而} \quad \lambda_\varepsilon \geq c_M \frac{\sqrt{d}}{\sigma}.$$

对高斯噪声 $\Delta_0 = 0$ ，条件无条件成立 (回收定理 4.1 的稠密情形)；对 Laplace、logistic、均匀噪声，条件在中等工作点处得到核验 (图 1)。状态：“条件 $\Rightarrow$ 稠密地板”这一蕴含已完全证明 (附录 B.8)；数值的部分是对非高斯律对假设 $\Delta_0 < \frac{1}{2} c \phi_M |t_d|$ 的核验 (图 1a)。故稠密 $\Omega(\sqrt{d})$ 地板对高斯为 Established，对对称对数凹噪声为以可检验不等式为条件的 Established——数值核证、而非一般性证明。(证明见附录 B.8。)

猜想 5.7 (无条件的分布无关地板). 命题 5.6 的稠密地板对全体对称对数凹噪声无条件成立——等价地 $\Delta_0 \leq \delta_1 := \sup_t [\Phi(t) - F_0(t)]_+$ ，即单坐标欠射 (图 1(a) 表明它很小且为卷积最坏情形)——并且超出对数凹性、对任何满足温和矩与反集中条件的噪声成立。障碍在于 Kolmogorov 距离欠射一般不沿卷积单调，故 $\Delta_0 \leq \delta_1$ 并非自动；直接的界，或完全非对数凹的情形，尚开放。

6 一个条件性的稳定秩特化

本节并非用稳定秩 $r_{\text{eff}} = \text{tr}(\Sigma)/\|\Sigma\|$ 一般性地替换 k_ε ：有效支持 k_ε 始终是定价量。毋宁说，命题 6.3 给出一叠条件 (EO0–EO4)，在其下 k_ε 特化为 $\Theta(r_{\text{eff}})$ ——即权重空间有效支持坍缩到数据空间稳定秩。这些条件之外 k_ε 与 r_{eff} 可不同 (注 6.6)。




Figure 1: 有效支持地板的分布普适性。(a) 命题 5.6 假设的一个数值核证：最大高斯欠射 $\Delta_0 = \sup_t [\Phi - G_a]_+$ (localize 的尾部好处) 对活跃坐标数 k , Laplace/logistic/均匀噪声；它在 $k=1$ 处最大、沿卷积递减，并在所述工作点处对三者皆低于稠密最优阈值 $\frac{1}{2} c \phi_M |t_d|$ (虚线, $\phi_M = \phi(M)$) ——核证了可检验不等式 (高斯给 $\Delta_0 \approx 0$)。 (b) 结论的一个经验示意：随 w localize (软阈值限于其 top- k 坐标)，鲁棒风险 $R(\varepsilon; w)$ 对每个对称对数凹律皆在稠密端 ($k=d$) 最小，与 w^* 稠密最优 ($k_\varepsilon = \Theta(d)$) 一致。面板 (a) 在此工作点核证充分条件 (非对所有工作点或所有对数凹律)；面板 (b) 示意由此得到的稠密最优性。

引理 6.1 (确定性前因子区间). 固定 ℓ_∞ 攻击基，并在本节始终假设 (EO0) Σ 在其中对角 (故 ℓ_1/ℓ_2 几何与 Σ -特征基对齐；非对齐情形带一个 coherence 修正，注 6.6)。则对任意 w ，几何前因子 $P(w) := \|w\|_1 / \|w\|_\Sigma$ ($\|w\|_\Sigma^2 := w^\top \Sigma w$) 满足确定性界

$$\frac{1}{\sqrt{\|\Sigma\|}} \cdot \frac{\|w\|_1}{\|w\|_2} \leq P(w) \leq \frac{1}{\sqrt{\lambda_{\min}(\Sigma)}} \cdot \frac{\|w\|_1}{\|w\|_2},$$

故价格因子被夹在平谱值 ($P = \frac{\|w\|_1}{\|w\|_2} / \sqrt{\|\Sigma\|}$ ，在顶特征值子空间达到) 与逆协方差膨胀值 (当 w 对齐最小方差方向时达到，此处 $P \rightarrow \sqrt{\text{tr}(\Sigma^{-1})}$) 之间。(证明见附录 B.11。)

引理 6.2 (平谱精确值). 若 Σ 限于 r 维子空间 V 上恰好平谱 ($\Sigma|_V = \|\Sigma\| I_r$)、 w 支撑于 V ，则精确等式 $P(w) = \frac{1}{\sqrt{\|\Sigma\|}} \cdot \frac{\|w\|_1}{\|w\|_2}$ 成立。特别地， $P(w) = \sqrt{r} / \sqrt{\|\Sigma\|}$ 当且仅当 w 在 V 上 delocalized，即其 participation ratio $(\|w\|_1 / \|w\|_2)^2 = \Theta(r)$ ；对尖峰 w (如单坐标) $P(w)$ 可小至 $1/\sqrt{\|\Sigma\|}$ 。仅支撑于 V 并不给出 $\sqrt{r}$ 因子。(证明见附录 B.12。)

命题 6.3 (对齐有效占据下 $k_\varepsilon = \Theta(r_{\text{eff}})$). 设 $r_{\text{eff}} := \text{tr}(\Sigma) / \|\Sigma\| \in [1, d]$, V_{eff} 为 Σ 顶 $\lceil r_{\text{eff}} \rceil$ 个特征方向所张，记有效信号 $a_\varepsilon := (|\mu| - \varepsilon)_+$ (下面对齐情形中鲁棒最优权重 $w_i^* \propto \text{sign}(\mu_i) a_{\varepsilon,i} / \lambda_i$ ，故设定 w^* participation ratio 的是 a_ε 而非 μ)。固定 ℓ_∞ 攻击基并假设：(EO0) 基对齐—— $\Sigma = \text{diag}(\lambda_i)$ 于攻击基，故 V_{eff} 由攻击基坐标张成、 ℓ_1 几何与特征基对齐；(EO1) 子谱平坦 $\lambda_{\max}(\Sigma|_{V_{\text{eff}}}) / \lambda_{\min}(\Sigma|_{V_{\text{eff}}}) \leq 1 + \rho'$ ；(EO2) 信号-尾控制 (在 Σ^{-1} 度量下) $\|P_{V_{\text{eff}}}^\perp \mu\|_{\Sigma^{-1}}^2 \leq \beta \|P_{V_{\text{eff}}} \mu\|_{\Sigma^{-1}}^2$ ，其中 $\|v\|_{\Sigma^{-1}}^2 := v^\top \Sigma^{-1} v$ ；(EO3) 有效信号 delocalization—— a_ε 限于 V_{eff} 时 delocalized, $\max_{i \in V_{\text{eff}}} a_{\varepsilon,i} / \|P_{V_{\text{eff}}} a_\varepsilon\|_2 = O(1/\sqrt{r_{\text{eff}}})$ ，故其 participation ratio 为 $\Theta(r_{\text{eff}})$ ；以及 (EO4) 次梯度-尾控制—— ℓ_1 次梯度 $s \in \partial \|w^*\|_1$ 满足 $\|P_{V_{\text{eff}}}^\perp \Sigma^{-1}(\varepsilon s)\|_\Sigma \leq \rho'' \|P_{V_{\text{eff}}} w^*\|_\Sigma$ (攻击项

不把质量泵入低方差尾)。则合并 (EO2) 与 (EO4), w^* 的尾满足

$$\|P_{V_{\text{eff}}^\perp} w^*\|_\Sigma \leq O(\beta + \rho' + \rho'') \|P_{V_{\text{eff}}} w^*\|_\Sigma,$$

故 w^* 的 Mahalanobis 主质量集中于 V_{eff} (尾泄漏受控, 非精确集中); 由 (EO1) $\|w^*\|_\Sigma^2 = (1 + O(\rho')) \|\Sigma\| \|P_{V_{\text{eff}}} w^*\|_2^2$, 由 (EO3) $w^*|_{V_{\text{eff}}}$ (正比于 $a_\varepsilon|_{V_{\text{eff}}}$) 的 participation ratio 为 $\Theta(r_{\text{eff}})$, 于是

$$P(w^*) \geq (1 - O(\rho' + \beta + \rho'')) \frac{\sqrt{r_{\text{eff}}}}{\sqrt{\|\Sigma\|}},$$

在完全对齐、平坦、占据、delocalized 的极限下取等 (引理 6.2); 从而 $\lambda_\varepsilon \geq c \frac{\sqrt{r_{\text{eff}}}}{\sqrt{\|\Sigma\|}} p_S(\varepsilon \|w^*\|_1 - \langle w^*, \mu \rangle)$ 。三种失效: 大 β (信号泄入低方差尾, $P(w^*) \rightarrow \sqrt{\text{tr} \Sigma^{-1}} \gg \sqrt{r_{\text{eff}}}$); 大 ρ'' (次梯度泵入尾质量); (EO3) 被违 ($a_\varepsilon|_{V_{\text{eff}}}$ 尖峰, 其解坐落于 $O(1)$ 个坐标, $P(w^*) = O(1)$)。 (证明见附录 B.13。) Conditional; 有效区域由 (ρ', β, ρ'') 与 delocalization (EO3) 界定。这给出猜想 6.5 中非自适应、基对齐的 $\sqrt{r_{\text{eff}}}$ 一半; 非对齐情形见注 6.6。

注 6.4 ((EO4) 是假设, 而非 (EO2) 的推论). (EO2) 与 (EO4) 控制不同的尾、逻辑上独立。(EO2) 界住信号尾 $\Sigma^{-1} \mu$; (EO4) 另行排除对抗次梯度-尾泵送——攻击的 ℓ_1 次梯度 $s \in \partial \|w^*\|_1$ 把 $\Sigma^{-1} s$ 质量驱入低方差方向。因 s 只被次微分钉到 (无效坐标上任意 $s_i \in [-1, 1]$), (EO4) 不能由 (EO2) 导出; 它是真正的假设, 须逐例设定或核验。它在图 2 的退化构造中平凡成立 (尾既无信号也无活跃坐标, 故次梯度尾为空); 它不由小尾特征值蕴含——那使 Σ^{-1} 在尾上变大, 正是次梯度-尾泵送最危险的体制——否则它是一个真实假设。

猜想 6.5 (自适应特征细化). 在自适应特征学习下, 表示——从而 Σ ——由训练塑造, $\sqrt{r_{\text{eff}}}$ 地板以学得表示的稳定秩 r_{eff} 成立。严格的自适应版本 (超出非自适应的命题 6.3) 尚开放。

注 6.6 (非对齐协方差与 coherence). 假设 (EO0) 是本质的: $k_\varepsilon = (\|\cdot\|_1 / \|\cdot\|_2)^2$ 在 ℓ_∞ 攻击基下度量, 而 r_{eff} 与 V_{eff} 是谱性的。当 Σ 在攻击基下非对角时, 等同 $P(w^*) \approx \sqrt{r_{\text{eff}} / \|\Sigma\|}$ 获得攻击坐标 e_i 与顶特征子空间之间的互相干因子 $\gamma := \max_i \|P_{V_{\text{eff}}} e_i\|_2$, 我们不对其定量控制 (不给出 coherence 修正的界)。完全相干的 Σ (特征向量在攻击基下 delocalized) 可把 k_ε 与 r_{eff} 完全解耦——定价维数仍是 k_ε , 但不再坍缩到 r_{eff} 。非对齐情形下建立锐的 coherence 修正地板尚开放。

7 局部深网推广

同一 $\sqrt{k_\varepsilon}$ 前因子在局部出现: 在任意 C^2 分类器的工作点处, 一阶敏感度携带其线性化判别的有效支持前因子。这是一个局部陈述 (工作点处的一阶代理), 而非网络的全局地板。

命题 7.1 (局部一阶敏感度; 确定性最坏情形). 设 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 为 C^2 分类器, x_0 为工作点, $w := \nabla f(x_0)$, $y := \text{sign}(f(x_0))$, 并设 $\kappa_\infty(x_0) := \sup_{s \in \{\pm 1\}^d} |s^\top \nabla^2 f(x_0) s|$ 为 ℓ_∞ 二次型曲率 (ℓ_∞ 球上的自然曲率度量, 避开谱范数界的 d 因子)。对 ℓ_∞ -有界对手 $\|\delta\|_\infty \leq \varepsilon$, 定义局部对抗边际 $g(\varepsilon; x_0) := \min_{\|\delta\|_\infty \leq \varepsilon} y f(x_0 + \delta)$ 。则在一阶有效邻域 $\varepsilon^2 \kappa_\infty(x_0) = o(\varepsilon \|w\|_1)$ 上,

$$g(\varepsilon; x_0) = y f(x_0) - \varepsilon \|w\|_1 + O(\varepsilon^2 \kappa_\infty), \quad \left. \frac{\partial g}{\partial \varepsilon} \right|_{\varepsilon \rightarrow 0} = -\|\nabla f(x_0)\|_1,$$

(确定性、最坏情形、分布无关)。对线性化判别 $w = \nabla f(x_0)$ 应用定理 4.1: 在提供密度 p_S 的独立输入噪声与 margin-density 条件下, 局部鲁棒边际价由前因子 $\|\nabla f(x_0)\|_1 / \|\nabla f(x_0)\|_2 = \sqrt{k_\varepsilon}$ 钉定——稠密 ∇f 时 $\Theta(\sqrt{d})$, 低有效秩下 $\sqrt{r_{\text{eff}}}$ (命题 6.3)。(证明见附录 B.9。) Established (最坏情形边际敏感度是确定性的; $\sqrt{d}$ 价格因子的密度部分继承定理 4.1 的随机扰动与 margin-density 条件)。

注 7.2 (范围: 局部代理, 非全局深网定理). 命题 7.1 是工作点 x_0 处的一阶 (线性化) 代理: 它把定理 4.1 应用于局部线性化 $w = \nabla f(x_0)$, 结论限于一阶有效邻域、由 κ_∞ 余项界定。它不是深网的全局鲁棒性定理; 跨多层非线性的严格全局下界是明确开放的问题。

注 7.3 (为 ReLU 网络估计 κ_∞). 对 ReLU 网络, $\nabla^2 f$ 几乎处处为零 (分段线性), 曲率作为奇异测度集中在激活边界超平面上; 经典 Hessian 谱不适用。 x_0 附近应把 κ_∞ 读作由跨最近激活边界的梯度跳变估计的有效曲率, $\kappa_\infty(x_0) \approx \sum_j \|\nabla f(x_0^+) - \nabla f(x_0^-)\| / \text{dist}(x_0, H_j)$, 对 ε -邻域内的边界 H_j 求和 (更近的边界贡献更大)。一次前向传播即给出激活模式、边界距离与双侧梯度差, 使之成为二阶修正的实用代理。

推论 7.4 (可微替代损失). 对可微替代损失及其诱导的光滑分类器, 替代鲁棒风险的局部一阶敏感度被 $c m_0 \|\nabla f(x_0)\|_1 / \|\nabla f(x_0)\|_2 = c m_0 \sqrt{k_\varepsilon}$ 从下界住, 其中 $m_0 > 0$ 是替代在工作边际处的局部导数下界。(证明见附录 B.10。)

8 蕴含与验证

8.1 一个廉价代理与测量之桥

当 $\varepsilon \rightarrow 0$, 昂贵的鲁棒侧价格被一个廉价的训练侧测量估计。

命题 8.1 ($\varepsilon \rightarrow 0$ 廉价代理). 当 $\varepsilon \rightarrow 0$, 鲁棒边际价被训练侧输入梯度对偶范数 $\hat{\lambda}_\varepsilon := \mathbb{E} \|\nabla_x \ell(x, y)\|_1$ 估计, 一次反向传播即可得。(证明见附录 A.5。)

命题 8.2 (Danskin 一阶展开; Hessian 项). 设 $\ell(\cdot, y)$ 在 x 的 ε -邻域内 C^2 、Hessian L_3 -Lipschitz。则

$$|\lambda_\varepsilon - \hat{\lambda}_\varepsilon| \leq \varepsilon \mathbb{E}[\kappa_\infty] + O(L_3 \varepsilon^2),$$

故代理一阶精确, 修正由 ℓ_∞ 二次型曲率 κ_∞ 控制。(证明见附录 A.6。)

注 8.3 (κ_∞ 的可计算性). 精确计算 $\kappa_\infty(x) = \max_{s \in \{\pm 1\}^d} s^\top \nabla^2 f(x) s$ 是布尔二次规划、NP-难, 但这不妨碍工程之桥。其一, κ_∞ 只进入命题 8.2 的价格修正 $\varepsilon \mathbb{E}[\kappa_\infty]$ (一个 $\varepsilon \rightarrow 0$ 时消失的 $O(\varepsilon)$ 项), 而测得的主项是 $\hat{\lambda}_\varepsilon = \mathbb{E} \|\nabla_x \ell\|_1$ (一次反向传播); 对 κ_∞ 的可计算上界即足够, 而粗糙谱界 $\kappa_\infty \leq \sqrt{d} \|\nabla^2 f\|_F$ (Hutchinson 迹估计) 可计算, 但由于 κ_∞ 进入 $O(\varepsilon)$ 价格项, 其 $\sqrt{d}$ 因子使该修正为 $O(\varepsilon \sqrt{d})$ ——仅在极小 ε 下可用; 下面的维数无关 SDP 上界更优。其二, κ_∞ 经布尔二次规划的半正定松弛有可计算的维数无关上界 (PSD 情形下 $\pi/2$ -定理 (Nesterov, 1998) 给出 $2/\pi$ 近似比; 不定情形下 SDP 仍返回有效上界, 但我们不主张锐的双侧近似比), 而随机符号向量采样给出下界。工程之桥只需该上界, 因 κ_∞ 仅进入 $O(\varepsilon)$ 修正项。

8.2 认证半径

推论 8.4 (认证半径; 二元信道约化). 对线性判别 w^* , 鲁棒风险达到 $\frac{1}{2}$ 的认证半径为 $\varepsilon_{\text{cert}} = \langle w^*, \mu \rangle / \|w^*\|_1$; 越过它分类器劣于随机, 在固定二元信道约化下不携带信息。(证明见附录 B.14。) Established (在该约化内)。

8.3 最优鲁棒半径

命题 8.5 (最优鲁棒半径 ε^{**} ; 存在性与比较静态). 设部署价值函数 $V: [0, \infty) \rightarrow \mathbb{R}_+$ 与鲁棒成本 $C: [0, \infty) \rightarrow \mathbb{R}_+$ 满足: (a) $V(\varepsilon) = K(1 - P_{\text{breach}}(\varepsilon))$, P_{breach} 严格递减、 C^1 , $P_{\text{breach}}(0) = 1$ 、 $P_{\text{breach}}(\infty) = 0$, $K > 0$ 为单次失陷损失; (b) $C(\varepsilon) = \int_0^\varepsilon \lambda_\varepsilon(\varepsilon') d\varepsilon'$, 边际成本 $C'(\varepsilon) = \lambda_\varepsilon$ 为 ε 处鲁棒价 (定理 4.1 在 margin-density 窗口内以 $c_M \sqrt{k_\varepsilon}/\sigma$ 下界之), $\lambda_0 := C'(0^+) = \lim_{\varepsilon \rightarrow 0^+} \lambda_\varepsilon$ 为 $\varepsilon \rightarrow 0^+$ 处 (过自信体制) 边际价, 一般 $\lambda_0 \ll c_M \sqrt{k_\varepsilon}/\sigma$; (c) $V'(\varepsilon) = K|P'_{\text{breach}}(\varepsilon)|$ 严格递减。设 $\varepsilon^{**} := \arg \max_\varepsilon [V(\varepsilon) - C(\varepsilon)]$ 。则: (i) 内部最优 $\varepsilon^{**} > 0$ 存在当且仅当 $K|P'_{\text{breach}}(0)| > C'(0^+) = \lambda_0$ (0 处净边际收益为正; 注意判据是真实边际成本 $C'(0^+) = \lambda_0$, 非 margin-density 窗口界 $c_M \sqrt{k_\varepsilon}/\sigma$); (ii) ε^{**} 唯一; (iii) 边界条件为 $K|P'_{\text{breach}}(\varepsilon^{**})| = \lambda_{\varepsilon^{**}}$; (iv) 经一个外生复杂度参数 π (如环境维 d , 或作为固定数据/表示属性的 r_{eff}) 的比较静态, π 使整条成本表上移, $\partial \lambda_\varepsilon / \partial \pi > 0$: 则 $\partial \varepsilon^{**} / \partial \pi < 0$ (提高边际成本降低最优半径), 特别地 $\partial \varepsilon^{**} / \partial K > 0$ 、 $\partial \varepsilon^{**} / \partial d < 0$ (“高复杂度模型经济上难以鲁棒化”)。我们对外生 π 求导, 非对内生 $k_\varepsilon = k_\varepsilon(\varepsilon)$ (其不能在改变选择变量 ε 的同时保持固定); (v) 在推论 8.4 的固定二元信道约化下, $\varepsilon^{**} \leq \varepsilon_{\text{cert}}$ 。(证明见附录 C。) Conditional; P_{breach} 由部署威胁模型提供, 非第一性原理。

注 8.6 (约化型模型). 命题 8.5 是约化型经济模型, 非攻防博弈: $P_{\text{breach}}(\varepsilon)$ 是对固定预算受限 ℓ_∞ 威胁模型的失陷概率, 按构造随认证半径递减。自适应攻击者只重塑 P_{breach} (预算受限时其对策的最坏情形仍随半径单调), 故一阶条件与比较静态——仅需 P_{breach} 单调与成本凸——得以保留。完整博弈是自然的推广。

8.4 合成验证

图 2 报告一个验证主结果的合成实验。跨三体制——稠密 μ 、 k -稀疏 μ 、满足有效占据的平子空间各向异性 Σ ——几何价格因子 $\sqrt{k_\varepsilon} = \|w^*\|_1 / \|w^*\|_2$ 对 $\sqrt{\text{有效维数}}$ 坍缩到一条直线: 线性拟合给 $\sqrt{k_\varepsilon} = 0.91 \sqrt{\text{eff. dim}}$ (斜率 ≈ 1); 等价地, $\sqrt{k_\varepsilon}$ 对有效维数的 log-log 斜率 $\approx \frac{1}{2}$ ——“维数税指数” $\frac{1}{2}$, 即同一 $\sqrt{\cdot}$ -尺度律的 log-log 形式 (二者是同一关系的两种坐标读法, 非两个不同斜率)。系数 $0.91 = \sqrt{0.836}$ 是软阈值在工作 ε 处的 participation-ratio 常数 ($k_\varepsilon / (\text{eff. dim}) \approx 0.836 < 1$), 是工作点常数而非对 $\sqrt{\cdot}$ -律的偏离。故 $\sqrt{d}$ 、 $\sqrt{k}$ 、 $\sqrt{r_{\text{eff}}}$ 是三个特例 $k_\varepsilon = \Theta(d), \Theta(k), \Theta(r_{\text{eff}})$ (定理 4.1、推论 4.4、命题 6.3)。蒙特卡洛边际价 $\partial \hat{R} / \partial \varepsilon$ 在恒等线上与闭式 $(\sqrt{k_\varepsilon}/\sigma)\phi(t(\varepsilon))$ 吻合, 验证引理 3.1 的闭式风险与价格; 工作点取 $\sigma \propto \|\mu\|_2$ (恒定 SNR $\rho = 1.5$), 置 $t \approx -1$ 于 margin-density 窗口内 (故 $c_M = \phi(-1) \approx 0.242$, 与拟合价格常数相符)。




Figure 2: 合成验证 (d 、 k 、 r_{eff} 扫描; $\sigma \propto \|\mu\|_2$ 、恒定 SNR $\rho = 1.5$, 工作点 $t \approx -1$ 于 margin-density 窗口)。(a) 稠密 μ 、 k -稀疏 μ 、平谱各向异性 Σ (满足有效占据) 的几何价格因子 $\sqrt{k_\varepsilon} = \|w^*\|_1 / \|w^*\|_2$ 对 $\sqrt{\text{有效维数}}$ 坍缩到一条直线 (线性斜率 ≈ 1 , 即 $\sqrt{k_\varepsilon} = 0.91\sqrt{\text{eff. dim}}$; 等价地 $\log\text{-log}$ 维数税指数 $\approx \frac{1}{2}$) , $\sqrt{d}$ 、 $\sqrt{k}$ 、 $\sqrt{r_{\text{eff}}}$ 为其三特例。(b) 蒙特卡洛边际价 $\partial \hat{R} / \partial \varepsilon$ 在恒等线上与闭式 $(\sqrt{k_\varepsilon} / \sigma) \phi(t)$ 吻合; 误差棒为 $\pm 2\sigma$ (bootstrap, 100 次重采样; 相对 $\leq 3.7\%$)。

技术细节 信号坐标 $\mu_i \sim \text{Unif}(0.5, 1.5)$ (稠密/稀疏体制在支撑上, 各向异性体制在平 top- r 子空间上、尾特征值消失); 维数扫描 $d \in \{16, \dots, 2048\}$ (稠密)、 $k \in \{8, \dots, 1024\}$ (稀疏, $d = 2048$)、 $r \in \{4, \dots, 256\}$ (各向异性, $d = 512$); 工作点 ε 固定于活跃区间内, $\sigma \propto \|\mu\|_2$ (恒定 SNR $\rho = 1.5$) 置 $t \approx -1$ 于 margin-density 窗口; $w^*(\varepsilon)$ 为闭式软阈值; 蒙特卡洛用 $N = 2 \times 10^6$ 样本, 直接采样投影 $\langle w, z \rangle \sim N(0, \|w\|_\Sigma^2)$, $\hat{\lambda}_\varepsilon$ 由中心差分估计; 斜率为过原点最小二乘拟合; 随机种子固定以便复现。

占据条件是必要的 (图 3) 两组扫描证实命题 6.3 的条件并非装饰。违反 (EO3) (令有效信号 a_ε 在平子空间上尖峰化) 使测得的 $k_\varepsilon / r_{\text{eff}}$ 从 1 降向 $O(1) / r_{\text{eff}}$ (全程从 1.00 到 0.02)。违反 (EO2) (把信号泄入低方差尾、抬高 β) 使实现的价格因子越过 $\sqrt{r_{\text{eff}} / \|\Sigma\|}$ 地板、升向 $\sqrt{\text{tr } \Sigma}^{-1}$ 上限 (此处至多 $\approx 19 \times$ 地板)。在 (EO0)–(EO4) 之外, k_ε 不坍缩到 r_{eff} 。

8.5 有效秩与低秩适配 (讨论)

本小节是讨论, 而非定理的推论。命题 6.3 的 $\sqrt{r_{\text{eff}}}$ 特化提示一种资源经济视角: 若学得表示的稳定秩 $r_{\text{eff}} \ll d$ 且满足对齐条件 (EO0)–(EO4), 鲁棒性的维数税将从 $\sqrt{d}$ 松弛向 $\sqrt{r_{\text{eff}}}$ 。这给出为何低秩适配 (LoRA/PEFT) 能以少量自由度维持鲁棒行为的一种条件性解读——与价格由 r_{eff} 而非环境维设定一致——但我们不主张因果或定量联系, 严格的自适应特征版本即开放的猜想 6.5。数量级 (仅为示意): 因价格按 $\sqrt{r_{\text{eff}}}$ 尺度, $r_{\text{eff}} \approx 10^4$ 降至 $\approx 10^2$ 会把前因子降低 $\sqrt{10^4 / 10^2} = 10$ 倍。




Figure 3: 稳定秩特化是有条件的 ($d = 512$, 平 $\text{top-}r_{\text{eff}}=64$ 子空间)。(a) 违反 (EO3): 随有效信号 $a_\varepsilon = (|\mu| - \varepsilon)_+$ 尖峰化 (指数 γ 增大), $k_\varepsilon / r_{\text{eff}}$ 从 1 (delocalized) 降向 $O(1)/r_{\text{eff}}$ ——仅支撑于 V_{eff} 不给出 $\Theta(r_{\text{eff}})$ 。(b) 违反 (EO2): 随信号泄入低方差尾 (β 增大), 实现的价格因子 $P(w^*) \sqrt{\|\Sigma\| / r_{\text{eff}}}$ 从 1 (地板) 升向 $\sqrt{\text{tr } \Sigma^{-1}}$ 上限。条件是必要的, 非装饰。

9 相关工作与局限

9.1 相关工作

定位 本文与五条工作线相关但相区别。(a) 影子价格/敏感性分析 (Fiacco, 1983; Rockafellar and Wets, 1998; Danskin, 1966; Clarke, 1990) 提供约束极值的一般包络/次梯度理论; 我们将其特化到作为一维预算的对抗半径, 并识别其定价单元 $\sqrt{k_\varepsilon}$ 。(b) CGMT + 对抗训练 (Thrapoulidis et al., 2015; Taheri et al., 2022; Javanmard and Soltanolkotabi, 2022) 精确刻画对抗训练的测试误差/精度; 我们的出发点是从序参量中读出 $\|\hat{w}\|_1 / \|\hat{w}\|_2 = \sqrt{k_\varepsilon}$ 作为定价量, 并将其与几何地板相连。(c) 结构化/低秩协方差与对抗鲁棒性: 近期高维分析把鲁棒性与特征协方差结构相连——Javanmard and Soltanolkotabi (2022) 处理各向异性高斯混合, Tanner et al. (2024) 的 Block Feature Model 刻画结构化 (正定) 攻防下与特征相关的鲁棒性; 我们提供定价机制 ($\sqrt{r_{\text{eff}}}$ 细化, 命题 6.3, conditional), 把低有效秩连到影子价格。(d) **participation ratio** 作为有效维数: participation ratio 及其倒数 (inverse participation ratio) 是凝聚态物理与随机矩阵理论中度量局域化与有效维数的标准量 (Anderson, 1958; Wegner, 1980; Evers and Mirlin, 2008), 亦是计算神经科学中数据有效维数的度量 (Gao et al., 2017); 据我们所知, 将其用作对抗鲁棒性的操作定价量 $k_\varepsilon = (\|w^*\|_1 / \|w^*\|_2)^2$ 是新的。(e) $\Omega(\sqrt{d})$ 型鲁棒性下界 (Schmidt et al., 2018; Bubeck and Sellke, 2021; Yin et al., 2019) 从样本复杂度/容量角度给出鲁棒性成本的维数下界; 我们的地板关乎边际价 (影子价格) 本身, 并把 $\sqrt{d}$ 细化为特例 $\sqrt{k_\varepsilon}$ 。

鲁棒机器学习 我们的边际价下界建立在鲁棒学习文献之上: 样本复杂度下界与鲁棒性-精度权衡 (Schmidt et al., 2018; Yin et al., 2019; Tsipras et al., 2019; Bubeck and Sellke, 2021) 从“需要多少数据/精度”角度刻画鲁棒成本; 我们与之互补, 把鲁棒成本视为价值函数关于半

径的边际，给出维数下界 $\Omega(\sqrt{k_\varepsilon})$ ——在稠密情形为 $\Omega(\sqrt{d})$ ，低有效秩下为 $\Omega(\sqrt{r_{\text{eff}}})$ 。 ℓ_∞/ℓ_1 对偶几何在高维饱和是熟知直觉；我们的贡献是把它嵌入价值函数的次梯度框架，给出 population $\sqrt{k_\varepsilon}$ 几何地板（定理 4.1，带来自软阈值 active 支持的绝对常数），而比例渐近锐常数由 CGMT 提供（命题 5.1）。

高维统计与 CGMT 命题 5.1 的比例渐近锐常数 $c(\kappa)$ 由凸高斯极小极大定理钉定 (Thrapoulidis et al., 2015)； ℓ_∞ 攻击、二分类、高斯混合下 $\hat{w}$ 的精确刻画归功于 Taheri et al. (2022) 与 Javanmard and Soltanolkotabi (2022)，我们由此特化读出 $\sqrt{k_\varepsilon}$ 尺度（稠密情形的 $\sqrt{d}$ 尺度）。定理 4.1 的 $\sqrt{k_\varepsilon}$ 地板本身是 population 几何，独立于比例渐近，带来自软阈值 active 支持的绝对常数 $c(\rho)$ 。相关技术见鲁棒线性回归的精确权衡 (Javanmard et al., 2020) 与高维 logistic 回归中正则的影响 (Salehi et al., 2019)。

9.2 局限

地板在高斯-线性体制下证明；分布无关版本（猜想 5.7）与自适应特征有效秩版本（猜想 6.5）尚开放。深网推广（命题 7.1）是工作点处的局部一阶代理，非跨多层非线性的全局鲁棒性定理。最优半径结果（命题 8.5）是约化型经济模型，其中失陷概率 P_{breach} 由部署威胁模型提供而非第一性原理导出。最后，CGMT 步（命题 5.1）是外部精确渐近定理的条件推论，在所引结果的非可分性与不动点唯一性下有效。

10 讨论与结论

我们论证了：对抗鲁棒的边际价 $\lambda_\varepsilon = \partial L^*/\partial \varepsilon$ ，作为约束价值函数的次梯度，存在一个维数地板，其正确定价单元是鲁棒最优判别的有效支持 $k_\varepsilon = (\|w^*\|_1/\|w^*\|_2)^2$ 。核心陈述是：对抗定价的操作维数是 k_ε ，而非环境维 d ： ℓ_∞ 攻击 $\Rightarrow \ell_1$ 对偶几何 $\Rightarrow$ 前因子 $\|w^*\|_1/\|w^*\|_2 = \sqrt{k_\varepsilon}$ ，且在 margin-density 窗口内 $\lambda_\varepsilon \geq c_M \sqrt{k_\varepsilon}/\sigma$ 。环境维 $\sqrt{d}$ 、稀疏度 $\sqrt{k}$ 、稳定秩 $\sqrt{r_{\text{eff}}}$ 是三个特例 $k_\varepsilon = \Theta(d), \Theta(k), \Theta(r_{\text{eff}})$ ；比例渐近锐常数由 CGMT 提供；下界经 ℓ_∞ 二次型曲率 κ_∞ 推广到任意 C^2 分类器的局部工作点。合成实验证实 $\sqrt{k_\varepsilon}$ 是三体制下的普适定价量。

工程解读为：鲁棒性的维数税由 ℓ_∞/ℓ_1 几何强制、而非可选；其从 $\sqrt{d}$ 到 $\sqrt{r_{\text{eff}}}$ 的松弛——以 § 6 的对齐有效占据条件 (EO0)–(EO4) 为条件——给出为何低有效秩表示可能降低鲁棒性与对齐边际成本的一种条件性解读。两个开放问题突出：超出高斯设计、对最优判别的分布无关地板（猜想 5.7），以及表示（从而协方差）由训练塑造的严格自适应特征 $\sqrt{r_{\text{eff}}}$ 细化（猜想 6.5）。后者尤将决定 $\Omega(\sqrt{d})$ 是普适下界，还是 lazy/固定特征体制的产物。

A 准备命题

A.1 定理 2.1（变分原理）的证明

在 (A1) 下，问题 $\min\{L(x) : g_i(x) \leq \varepsilon_i\}$ 为凸规划；在 (A2) (Slater 或 MFCQ) 下 KKT 条件为最优性的充要条件，故存在乘子 $\lambda \geq 0$ 使 $\nabla L(x^*) + \sum_i \lambda_i \nabla g_i(x^*) = 0$ 且 $\lambda_i(g_i(x^*) - \varepsilon_i) = 0$ （参

见 Rockafellar 与 Wets, 1998; Bertsekas, 1999)。乘子未必唯一。在 (A3) LICQ 下 active 梯度系统列满秩，故平稳性方程唯一确定 λ ；或 (A3') 严格互补加二阶充分条件，经对 KKT 系统的隐函数定理给出唯一性。可微限制及其与唯一性的等价见附录 A.2。□

A.2 命题 2.2 (影子价格=梯度) 的证明

这是 (非光滑) 包络定理。记 Lagrangian $\mathcal{L}(x, \lambda; \mathcal{E}) = L(x) + \sum_i \lambda_i (g_i(x) - \mathcal{E}_i)$ ，在最优处 $\partial \mathcal{L} / \partial \mathcal{E}_i = -\lambda_i$ 。当 L^* 在 $\mathcal{E}$ 处可微 (等价地乘子唯一，由 (A3)/(A3'))，Danskin 定理给 $\partial L^* / \partial \mathcal{E}_i = -\lambda_i$ 。一般而言 L^* 是关于 $\mathcal{E}$ 仿射函数的逐点极小，故凹且局部 Lipschitz，由 Rademacher 定理几乎处处可微；在不可微点 $-\lambda \in \partial_{\mathcal{E}} L^*$ (Clarke 次微分)，它是乘子集的凸包，在 ε 方向退化为 Danskin 区间。□

A.3 推论 2.3 (边际相等) 的证明

在 $\max\{-L^*(\mathcal{E}) : \sum_i \mathcal{E}_i \leq B\}$ 的最优处，平稳性条件把各 active 坐标上的 $\partial L^* / \partial \mathcal{E}_i = -\lambda_i$ 等同于总预算约束的一个公共 Lagrange 乘子；故各 active 维度上每单位预算购得的边际损失下降相等。□

A.4 读出算子 (由 § 2 移入)

定义 A.1 (读出算子). 对闭子空间 $Y \subseteq X$ 、含入映射 $\iota_Y: Y \rightarrow X$ ， ∂L^* 沿 Y 的读出是含入-伴随限制 $\Pi_Y: X^* \rightarrow Y^*$ ， $\Pi_Y \partial L^* = \{\xi|_Y : \xi \in \partial L^*\}$ 。两个特出读数为 $\Pi_{\text{train}} := \Pi_U$ (沿训练控制) 与 $\Pi_{\text{robust}} := \Pi_{\varepsilon}$ (沿对抗半径)。

命题 A.2 (两种读出). 在 § 2 设定下、且 L^* 单值处， $\Pi_{\text{train}}(\nabla L^*) = \lambda(t)$ (协态)， $\Pi_{\text{robust}}(\partial L^*) = \partial_{\varepsilon} L^* = [\lambda_{\varepsilon}^-, \lambda_{\varepsilon}^+]$ (Clarke 次微分，几乎处处单值，临界集上为 Danskin 区间)。故协态读出与鲁棒读出是同一对象沿不同轴之所见——“换轴，不换机器”——且 $\varepsilon \rightarrow 0$ 时鲁棒价等于训练侧输入梯度对偶范数、至一个 Hessian 余项 (由命题 8.2 定量化)。

证明. 断言为 $\Pi_Y = \iota_Y^*$ (含入 $\iota_Y: Y \rightarrow X$ 之伴随) 限于 ∂L^* 。对次梯度 $\xi \in \partial L^* \subseteq X^*$ ，其在 Y 上的作用为 $\langle \xi, \iota_Y y \rangle = \langle \iota_Y^* \xi, y \rangle$ ，即 $\xi|_Y = \iota_Y^* \xi$ 。取 $Y = U$ (训练控制) 经 Pontryagin 原理回收协态 $\lambda(t)$ ，取 $Y = \mathbb{R}_{\varepsilon}$ 回收 $\partial_{\varepsilon} L^*$ 。三者皆为单一集合 ∂L^* 在限制下的像，故为同一对象的读出；几乎处处单值性由附录 A.2 得。□

A.5 命题 8.1 ($\varepsilon \rightarrow 0$ 廉价代理) 的证明

由 Danskin 定理， $\partial_{\varepsilon} \mathbb{E} \max_{\|\delta\|_{\infty} \leq \varepsilon} \ell(x + \delta, y) \big|_{\varepsilon=0} = \mathbb{E} \max_{\|u\|_{\infty} \leq 1} \langle u, \nabla_x \ell(x, y) \rangle = \mathbb{E} \|\nabla_x \ell(x, y)\|_1$ ，因 ℓ_{∞} -球的支撑函数是 ℓ_1 范数 (最坏单位方向为 $u = \text{sign}(\nabla_x \ell)$)。故 $\hat{\lambda}_{\varepsilon} = \mathbb{E} \|\nabla_x \ell\|_1$ 是精确的 $\varepsilon \rightarrow 0$ 导数，由一次反向传播得。□

A.6 命题 8.2 (Hessian 项) 的证明

设 $\delta^*(\varepsilon) = \arg \max_{\|\delta\|_\infty \leq \varepsilon} \ell(x + \delta, y)$ 。二阶 Taylor 展开给 $\ell(x + \delta^*, y) = \ell(x, y) + \langle \nabla_x \ell, \delta^* \rangle + \frac{1}{2} \delta^{*\top} \nabla_x^2 \ell \delta^* + O(L_3 \varepsilon^3)$ 。主项在 $\delta^* = \varepsilon \text{sign}(\nabla_x \ell)$ 处取极大、给 $\varepsilon \|\nabla_x \ell\|_1$ ；二次修正被 $\frac{1}{2} \max_{s \in \{\pm 1\}^d} \varepsilon^2 s^\top \nabla_x^2 \ell s = \frac{\varepsilon^2}{2} \kappa_\infty$ 界住。余项 $R(\varepsilon) := \frac{1}{2} \delta^{*\top} \nabla_x^2 \ell \delta^* = \frac{\varepsilon^2}{2} s^\top \nabla_x^2 \ell s$ ($s = \text{sign}(\nabla_x \ell)$) 有 $|R(\varepsilon)| \leq \frac{\varepsilon^2}{2} \kappa_\infty$ ，但价格是其导数 $R'(\varepsilon) = \varepsilon s^\top \nabla_x^2 \ell s$ ，故 $|R'(\varepsilon)| \leq \varepsilon \kappa_\infty$ 。取期望， $|\lambda_\varepsilon - \hat{\lambda}_\varepsilon| \leq \varepsilon \mathbb{E}[\kappa_\infty] + O(L_3 \varepsilon^2)$ 。□

B 主要证明

B.1 引理 3.1 (闭式鲁棒风险与价格) 的证明

对 $x = y\mu + z$ 与线性判别，(带符号) 干净边际为 $y\langle w, x \rangle = \langle w, \mu \rangle + y\langle w, z \rangle$ 。对半径 ε 的 ℓ_∞ 对手，最坏扰动解 $\min_{\|\delta\|_\infty \leq \varepsilon} y\langle w, x + \delta \rangle = y\langle w, x \rangle - \varepsilon \|w\|_1$ (w 的 ℓ_∞ -球支撑函数为 $\varepsilon \|w\|_1$)，故误分类当且仅当 $y\langle w, x \rangle < \varepsilon \|w\|_1$ 。因 $y\langle w, z \rangle \sim N(0, \sigma^2 \|w\|_2^2)$ (由 y, z 对称)，

$$R(\varepsilon; w) = \mathbb{P}(\langle w, \mu \rangle + y\langle w, z \rangle < \varepsilon \|w\|_1) = \Phi\left(\frac{\varepsilon \|w\|_1 - \langle w, \mu \rangle}{\sigma \|w\|_2}\right) = \Phi(t(w)).$$

固定 w 求导 (Danskin: 最优处全导数等于偏导)， $\partial R / \partial \varepsilon = \phi(t) \cdot \|w\|_1 / (\sigma \|w\|_2) = (\sqrt{k_\varepsilon(w)} / \sigma) \phi(t)$ ， $k_\varepsilon(w) = (\|w\|_1 / \|w\|_2)^2$ 。□

B.2 定理 4.1 (有效支持地板) 的证明

第 1 步 (约化)。由引理 3.1， $R(\varepsilon; w) = \Phi(t(w))$ ， $t(w) = (\varepsilon \|w\|_1 - \langle w, \mu \rangle) / (\sigma \|w\|_2)$ 。因 Φ 严格递增，鲁棒最优 $w^*(\varepsilon) = \arg \min_w R = \arg \min_w t(w)$ ，由尺度不变性可设 $\|w\|_2 = 1$ ；问题化为 $\min_{\|w\|_2=1} \varepsilon \|w\|_1 - \langle w, \mu \rangle$ 。

第 2 步 (符号对齐)。最优处每个 active 坐标 $\text{sign}(w_i) = \text{sign}(\mu_i)$ (翻转符号严格减小 $-\langle w, \mu \rangle$ 而不改变 $\|w\|_1, \|w\|_2$)。记 $u_i = \text{sign}(\mu_i) w_i \geq 0$ ，问题为 $\max_{\|u\|_2=1, u \geq 0} \sum_i (|\mu_i| - \varepsilon) u_i$ 。

第 3 步 (软阈值解)。这是线性泛函在单位球与正卦限之交上的极大化；最优方向为系数向量的正部， $u \propto (|\mu| - \varepsilon)_+$ ，即

$$w_i^* \propto \text{sign}(\mu_i) (|\mu_i| - \varepsilon)_+.$$

仅 $|\mu_i| > \varepsilon$ 的坐标存活，因 ℓ_∞ 攻击项 $\varepsilon \|w\|_1$ 贡献逐坐标次梯度 $\varepsilon \text{sign}(w_i)$ 、与信号 μ_i 竞争；active 支持为 $S_\varepsilon = \{i : |\mu_i| > \varepsilon\}$ 。

第 4 步 (地板)。按构造 $k_\varepsilon = (\|w^*\|_1 / \|w^*\|_2)^2$ 是 $(|\mu| - \varepsilon)_+$ 在 S_ε 上的 participation ratio。由引理 3.1， $\lambda_\varepsilon = (\sqrt{k_\varepsilon} / \sigma) \phi(t(\varepsilon))$ 。在 margin-density 窗口 $|t(\varepsilon)| \leq M$ 上密度有下界， $\phi(t) \geq \phi(M) =: c_M$ (ϕ 单峰偶，故 $|t| \leq M$ 时 $\phi(t) \geq \phi(M)$)，从而 $\lambda_\varepsilon \geq c_M \sqrt{k_\varepsilon} / \sigma$ 。对 delocalized 稠密信号 ($|\mu_i| = \Theta(\|\mu\|_2 / \sqrt{d})$)， $|S_\varepsilon| = \Theta(d)$ 、 ℓ_∞ -可比向量的 participation ratio 为 $\Theta(d)$ ，给 $k_\varepsilon = \Theta(d)$ 与 $\Omega(\sqrt{d})$ 特例。常数 $c_M = \phi(M)$ 仅依赖 M (从而仅依赖工作 SNR ρ)。□

B.3 命题 5.1 (由 CGMT 不动点的显式读出) 的推导

这是外部定理的特化，非新的 CGMT 证明。约化。对递减损失，内层 ℓ_∞ 极大化由 $\delta_i^* = -y_i \text{sign}(\theta) \varepsilon_{\text{tr}} / \sqrt{d}$ 解，把鲁棒 ERM 约化为凸规划 $\min_\theta \sum_i L(y_i \langle x_i, \theta \rangle - \frac{\varepsilon_{\text{tr}}}{\sqrt{d}} \|\theta\|_1) + r \|\theta\|_2^2$ (Taheri et al., 2022, 式 9)，其中 ℓ_∞ 攻击已化为损失内部一个“有效” ℓ_1 项。标量化。其 CGMT 分析（其定理 1）把关联辅助优化标量化为八标量凸-凹鞍点（其式 7）于 $(\alpha, \tau_1, \omega, \nu, \tau_2, \beta, \gamma, \eta)$ (ω 为其标量序参量，区别于我们的向量 w^*)，其中 $|\cdot|$ 的 Moreau 包络经 ℓ_1 对偶编码 ℓ_∞ 攻击；在非可分性与 ridge 强凸下解唯一。读出。其引理 2 识别序参量极限 $\varepsilon_{\text{tr}} \|\hat{\theta}\|_1 / \sqrt{d} \rightarrow \omega^*$ 、 $\|P_\mu \hat{\theta}\|_2 \rightarrow \nu^*$ 、 $\|P_\mu^\perp \hat{\theta}\|_2 \rightarrow \alpha^*$ ，故 $\|\hat{\theta}\|_2 \rightarrow \sqrt{\nu^{*2} + \alpha^{*2}}$ 。取比值，

$$\frac{\|\hat{\theta}\|_1}{\|\hat{\theta}\|_2} = \frac{\omega^* / \varepsilon_{\text{tr}}}{\sqrt{\nu^{*2} + \alpha^{*2}}} \sqrt{d} + o(\sqrt{d}) = c(\kappa) \sqrt{d}, \quad c(\kappa) = \frac{\omega^*}{\varepsilon_{\text{tr}} \sqrt{\nu^{*2} + \alpha^{*2}}}.$$

对稠密 D (delocalized μ) 不动点有 $\omega^* > 0$ 、 $\sqrt{\nu^{*2} + \alpha^{*2}} = \Theta(1)$ ，故 $\|\hat{\theta}\|_1 = \Theta(\sqrt{d})$ 、 $\|\hat{\theta}\|_2 = \Theta(1)$ 、 $k_\varepsilon(\hat{\theta}) = c(\kappa)^2 d = \Theta(d)$ 。代入引理 3.1 给 margin-density 窗口内 $\hat{\lambda}_\varepsilon = (c(\kappa) \sqrt{d} / \sigma) \phi(t)$ 。Population 极限。当 $\kappa = m/d \rightarrow \infty$ ， m 个损失项主导固定 ridge，有效正则 $\rightarrow 0$ ，式 7 鞍点形式上退化为定理 4.1 的无正则 population 规划，故我们预期 $c(\kappa) \rightarrow c(\rho)$ ；我们不作严格极限所需的一致不动点控制。假设核对见注 5.2。□

B.4 推论 4.4 (稀疏信号) 的证明

若 μ 支撑于 k 个坐标，则 $S_\varepsilon = \{i : |\mu_i| > \varepsilon\} \subseteq \text{supp}(\mu)$ 至多 k 元，且对低于稀疏信号尺度的 ε ， $|S_\varepsilon| = \Theta(k)$ 。由附录 B.2 第 3–4 步， $w_i^* \propto \text{sign}(\mu_i) a_{\varepsilon, i}$ 支撑于 S_ε ，故 $k_\varepsilon = (\|w^*\|_1 / \|w^*\|_2)^2$ 是 a_ε 在 S_ε 上的 participation ratio；这为 $\Theta(k)$ 当且仅当 a_ε 于该处 delocalized (仅支撑不足，参见引理 6.2)。在该 delocalization 下， $k_\varepsilon = \Theta(k)$ 、 $\lambda_\varepsilon \geq c_M \sqrt{k} / \sigma$ 。□

B.5 命题 5.3 (亚高斯普适性) 的证明

固定 delocalized 的 w ($\|w\|_\infty / \|w\|_2 = O(1/\sqrt{d})$)。投影 $S := \langle w, z \rangle = \sum_i w_i z_i$ 是独立零均值亚高斯项之和、 $\max_i |w_i| / \|w\|_2 \rightarrow 0$ ，故由 Lindeberg/局部 CLT 论证，标准化 $S / \|w\|_2$ 收敛到 $N(0, \tau^2)$ ；delocalization 与局部-CLT 假设 (有界密度/Cramér 条件) 给出密度 p_S 的收敛，而非仅 CDF。则 $\lambda_\varepsilon(w) = \|w\|_1 p_S(\varepsilon \|w\|_1 - \langle w, \mu \rangle)$ 保留 $\|w\|_1 = \Theta(\sqrt{d} \|w\|_2)$ 前因子，常数经 p_S 与 τ 承载。Berry–Esseen 只界 $|F_S - \Phi|$ 而非 $|p_S - \phi|$ ，故需局部极限假设。□

B.6 引理 5.4 (对数凹密度地板) 的证明

设 g 为对称对数凹、方差 1、CDF 为 F ；我们以自足的 reverse-hazard 论证证明显式地板 $c_M = \alpha_0/4$ (α_0 为下述 margin-density 水平)。

第 1 步 ($g(0) \geq \frac{1}{8}$)。由 Chebyshev $P(|X| \leq 2) \geq 1 - \frac{1}{4} = \frac{3}{4}$ ，故 $F(2) \geq \frac{7}{8}$ ，满足 $F(q) = \frac{3}{4}$ 的点 $q \leq 2$ 。因对称与单峰使 g 在 $[0, \infty)$ 非增， $\frac{1}{4} = \int_0^q g \leq q g(0) \leq 2g(0)$ ，故 $g(0) = \|g\|_\infty \geq \frac{1}{8}$ 。

第 2 步 (reverse hazard)。 g 的对数凹性使 F 对数凹，故 reverse hazard $g/F = (\log F)'$ 非增 (Bagnoli and Bergstrom, 2005)；亦见 Saumard and Wellner (2014) 的综述。故对每个 $t \leq 0$ ， $g(t)/F(t) \geq g(0)/F(0) = 2g(0)$ ，即 $g(t) \geq 2g(0)F(t)$ 。

第 3 步（工作点处的地板）。margin-density 窗口恰是鲁棒精度非平凡的陈述：工作点有 $F(t(w^*)) = R(\varepsilon; w^*) \geq \alpha_0 > 0$ （常数 α_0 ，等价地 $|t| \leq M$ 、 $\alpha_0 = \Phi(-M)$ ），且 $t(w^*) < 0$ （因 $R < \frac{1}{2}$ ）。合并第 1-2 步， $g(t(w^*)) \geq 2g(0)\alpha_0 \geq \alpha_0/4 =: c_M > 0$ ，一个仅依赖 α_0 （从而 M ）、与噪声律无关的绝对常数。这也处理有界支撑律（如均匀）：任何 $F(t) \geq \alpha_0 > 0$ 的工作点位于支撑内部、 $g > 0$ ，故除 margin-density 假设本身外无需支撑附注。

最后，对 iid 对称对数凹 z_i ，投影 $\langle w, z \rangle$ 是对称对数凹律的卷积、故对称对数凹（Prékopa 定理）；归一化到单位方差后， $\tilde{S}$ 满足假设、窗口上 $p_{\tilde{S}}(t) \geq c_M$ 。□

B.7 定理 5.5（分布无关地板）的证明

引理 3.1 的价格恒等式对任何有密度的噪声成立： $\lambda_\varepsilon(w^*) = \|w^*\|_1 p_S(\tau) = \frac{\|w^*\|_1}{\sigma \|w^*\|_2} p_{\tilde{S}^*}(t(w^*)) = \frac{\sqrt{k_\varepsilon}}{\sigma} p_{\tilde{S}^*}(t(w^*))$ ， $\tilde{S}^* = \langle w^*, z \rangle / (\sigma \|w^*\|_2)$ 。由引理 5.4， $\tilde{S}^*$ 对称对数凹、单位方差，故在 margin-density 工作点 $|t(w^*)| \leq M$ （支撑内部，因该处鲁棒精度非平凡）其密度满足 $p_{\tilde{S}^*}(t(w^*)) \geq c_M$ 。故 $\lambda_\varepsilon(w^*) \geq c_M \sqrt{k_\varepsilon} / \sigma$ ， c_M 在对称对数凹类上绝对。不用 CLT 或比例渐近极限。□

B.8 命题 5.6（分布无关稠密地板）的证明

直观。稠密软阈值极小化标准化边际 t ；localize 的竞争者只能靠利用比高斯更薄的尾降低风险（至多值 Δ_0 ），却付出每单位值 ϕ_M 的边际亏损。二者平衡给阈值 $\Delta_0 < \frac{1}{2} c \phi_M |t_d|$ 。形式地：对齐符号使 $\mu_i > 0$ 、 $w_i \geq 0$ ；active 坐标上 $t(w) = -\langle \hat{w}, a_\varepsilon \rangle / \sigma$ 、 $\hat{w} = w / \|w\|_2$ 单位。全程 $\phi_M := \phi(M)$ 表窗口边缘处高斯密度（仅用于下界 Φ 之差），区别于引理 5.4 的对数凹密度地板 c_M （仅用于最终价格）。

第 1 步（边际亏损恒等式）。由 Cauchy-Schwarz $\min_w t(w) = t_d = -\|a_\varepsilon\|_2 / \sigma$ ，在 $\hat{w} = \hat{a}_\varepsilon$ 达到；对任意单位 $\hat{w}$ ，

$$t(w) - t_d = \frac{\|a_\varepsilon\|_2}{\sigma} (1 - \langle \hat{w}, \hat{a}_\varepsilon \rangle) = \frac{|t_d|}{2} \|\hat{w} - \hat{a}_\varepsilon\|_2^2, \quad (\dagger)$$

用单位向量的 $1 - \langle \hat{w}, \hat{a}_\varepsilon \rangle = \frac{1}{2} \|\hat{w} - \hat{a}_\varepsilon\|_2^2$ 。

第 2 步（风险比较）。设 w_{ST}^* 为稠密软阈值。两事实夹住竞争者相对它的风险：

- (a) 竞争者下界。由 $\Delta_0 = \sup_{a,t} [\Phi(t) - G_a(t)]_+$ 的定义，每个方向与点满足 $G_a(t) \geq \Phi(t) - \Delta_0$ ；故 $R(w) = G_{\hat{w}}(t(w)) \geq \Phi(t(w)) - \Delta_0$ 。
- (b) 稠密上界。对 delocalized 的 $\hat{a}_\varepsilon$ ($\eta_0 = \|\hat{a}_\varepsilon\|_\infty = O(1/\sqrt{d})$)，Berry-Esseen 给 $R(w_{\text{ST}}^*) = G_{\hat{a}_\varepsilon}(t_d) \leq \Phi(t_d) + C_{BE\rho_3}\eta_0 = \Phi(t_d) + o(1)$ 。
- (a) 减 (b)、并以窗口上的高斯密度下界 Φ 之差，

$$R(w) - R(w_{\text{ST}}^*) \geq [\Phi(t(w)) - \Phi(t_d)] - \Delta_0 - o(1) \geq \phi_M [t(w) - t_d] - \Delta_0 - o(1),$$

（中值定理， $\phi \geq \phi(M)$ ）对 $t(w) \leq M$ 有效（若 $t(w) > M$ 则 $R(w) \geq \Phi(M) - \Delta_0 > R(w_{\text{ST}}^*)$ 平凡成立，此类 w 已被排除）。

第 3 步（ Δ_0 阈值）。真实最优有 $R(w^*) \leq R(w_{\text{ST}}^*)$ ，故上式迫使 $\phi_M [t(w^*) - t_d] \leq \Delta_0 + o(1)$ ；代入 (†)，

$$\|\hat{w}^* - \hat{a}_\varepsilon\|_2^2 \leq \frac{2\Delta_0}{\phi_M |t_d|} + o(1) =: \theta_0.$$

故非零尾部好处 Δ_0 只为优化器买到偏离稠密方向的有界角偏差 θ_0 ，而 $\theta_0 < 1$ 恰当 $\Delta_0 < \frac{1}{2}\phi_M|t_d|_0$ 。

第4步 (delocalization $\Rightarrow k_\varepsilon$)。因 $\hat{a}_\varepsilon$ 支撑于 cd 个 active 坐标， $\|\hat{w}^\star\|_1 \geq \|\hat{a}_\varepsilon\|_1 - \sqrt{cd}\|\hat{w}^\star - \hat{a}_\varepsilon\|_2 \geq \sqrt{cd}(1 - \sqrt{\theta_0})$ ，故 $k_\varepsilon(w^\star) = \|\hat{w}^\star\|_1^2 \geq cd(1 - \sqrt{\theta_0})^2 = \Theta(d)$ ，只要 $\theta_0 < c$ ，即 $\Delta_0 < \frac{1}{2}c\phi_M|t_d|_0$ 。合并定理 5.5 的 k_ε -地板 (提供密度因子 c_M)， $\lambda_\varepsilon \geq c_M\sqrt{d}/\sigma$ 。对高斯噪声 $G_a = \Phi$ ，故 $\Delta_0 = 0$ 、条件空虚，回收定理 4.1 的稠密情形。□

B.9 命题 7.1 (局部深网敏感度) 的证明

在 x_0 处 Taylor 展开 f : $f(x_0 + \delta) = f(x_0) + \langle \nabla f(x_0), \delta \rangle + \frac{1}{2}\delta^\top \nabla^2 f(x_0)\delta + o(\|\delta\|^2)$ 。极小化 yf 的最坏 ℓ_∞ 扰动把一阶部分取到 $-\varepsilon\|\nabla f(x_0)\|_1$ (ℓ_∞ 球支撑函数)，二次部分被 $\frac{1}{2}\varepsilon^2 \max_{s \in \{\pm 1\}^d} |s^\top \nabla^2 f s| = \frac{1}{2}\varepsilon^2 \kappa_\infty$ 界住。故 $g(\varepsilon; x_0) = yf(x_0) - \varepsilon\|w\|_1 + O(\varepsilon^2 \kappa_\infty)$ 、 $\varepsilon \rightarrow 0$ 时 $\partial g / \partial \varepsilon \rightarrow -\|\nabla f(x_0)\|_1$ 。把 $w = \nabla f(x_0)$ 视为线性化判别、在有密度 p_S 的输入噪声与 margin-density 下应用引理 3.1 / 定理 4.1，局部价被前因子 $\|\nabla f(x_0)\|_1 / \|\nabla f(x_0)\|_2 = \sqrt{k_\varepsilon}$ 从下界住。有效性限于邻域 $\varepsilon^2 \kappa_\infty = o(\varepsilon\|w\|_1)$ (注 7.2)。□

B.10 推论 7.4 (可微替代) 的证明

对可微替代 ψ 、在工作边际处 $\psi' \leq -m_0 < 0$ ，替代鲁棒风险 $\mathbb{E}\psi(g(\varepsilon; x_0))$ 的 ε -导数为 $\mathbb{E}[\psi'(g) \partial_\varepsilon g]$ ；用 $\partial_\varepsilon g \rightarrow -\|\nabla f\|_1$ 与 $|\psi'| \geq m_0$ 得下界 $c m_0 \|\nabla f(x_0)\|_1 / \|\nabla f(x_0)\|_2 = c m_0 \sqrt{k_\varepsilon}$ 。□

B.11 引理 6.1 (确定性区间) 的证明

由 (EO0)， $\Sigma = \text{diag}(\lambda_i)$ 于攻击基。记 $P(w) = \|w\|_1 / \|w\|_\Sigma$ 。因 $\lambda_{\min}(\Sigma)\|w\|_2^2 \leq \|w\|_\Sigma^2 \leq \|\Sigma\|\|w\|_2^2$ ，得 $\frac{1}{\sqrt{\|\Sigma\|}} \frac{\|w\|_1}{\|w\|_2} \leq P(w) \leq \frac{1}{\sqrt{\lambda_{\min}(\Sigma)}} \frac{\|w\|_1}{\|w\|_2}$ 。下值 $\|w\|_1 / (\|w\|_2 \sqrt{\|\Sigma\|})$ 是平谱值 (顶特征值子空间)；上值当 w 对齐最小方差方向时达到，此处 $P \rightarrow \sqrt{\text{tr}(\Sigma^{-1})}$ 。无 (EO0) 时， $\|w\|_1$ (攻击基) 与 $\|w\|_\Sigma$ (特征基) 只经注 6.6 的 coherence 因子相关。□

B.12 引理 6.2 (平谱) 的证明

若 $\Sigma|_V = \|\Sigma\|I_r$ 、 w 支撑于 V ，则 $\|w\|_\Sigma^2 = \|\Sigma\|\|w\|_2^2$ ，给精确等式 $P(w) = \|w\|_1 / (\sqrt{\|\Sigma\|}\|w\|_2) = (\|w\|_1 / \|w\|_2) / \sqrt{\|\Sigma\|}$ 。因子 $\|w\|_1 / \|w\|_2 \in [1, \sqrt{r}]$ 等于 participation ratio 的平方根，故 $P(w) = \sqrt{r} / \sqrt{\|\Sigma\|}$ 成立当且仅当 w 在 V 上 delocalized (participation ratio $\Theta(r)$)；尖峰 w (如单坐标) 给 $\|w\|_1 / \|w\|_2 = 1$ 、 $P(w) = 1 / \sqrt{\|\Sigma\|}$ 。仅支撑于 V 不足；需 delocalization (对软阈值解由命题 6.3 的 (EO3) 提供)。□

B.13 命题 6.3 ($\sqrt{r_{\text{eff}}}$ 地板) 的证明

在 ℓ_∞ 攻击基中工作，由 (EO0) $\Sigma = \text{diag}(\lambda_i)$ ；鲁棒最优权重 $w^\star \propto \Sigma^{-1}(\mu - \varepsilon s)$ ， $s \in \partial\|w^\star\|_1$ 、 $|s_i| \leq 1$ ，故 active 坐标上 $w_i^\star \propto \text{sign}(\mu_i)(|\mu_i| - \varepsilon) / \lambda_i = \text{sign}(\mu_i)a_{\varepsilon,i} / \lambda_i$ 。信号质量。由 (EO2)， $\|P_{V_{\text{eff}}}^\perp \mu\|_{\Sigma^{-1}}^2 \leq \beta \|P_{V_{\text{eff}}} \mu\|_{\Sigma^{-1}}^2$ ，故 $\Sigma^{-1}\mu$ 的 Mahalanobis 质量有 $(1 - O(\beta))$ 份落在 V_{eff} ，排除低方差尾中的信

号放大。次梯度质量。 ℓ_1 -次梯度项贡献尾能量 $\|P_{V_{\text{eff}}^\perp} \Sigma^{-1}(\varepsilon s)\|_\Sigma$ ，正是 (EO4) 以 $\rho'' \|P_{V_{\text{eff}}} w^*\|_\Sigma$ 界住者；我们取之为假设而非导出，因 s 只被次微分钉到。合并两尾， $\|P_{V_{\text{eff}}^\perp} w^*\|_\Sigma \leq O(\beta + \rho' + \rho'') \|P_{V_{\text{eff}}} w^*\|_\Sigma$ 。前因子。由 (EO1)， $\|w^*\|_\Sigma^2 = (1 + O(\rho')) \|\Sigma\| \|P_{V_{\text{eff}}} w^*\|_\Sigma^2$ 。在平的 V_{eff} 上 $w^*|_{V_{\text{eff}}} \propto a_\varepsilon|_{V_{\text{eff}}}$ ，故由 (EO3) 其 participation ratio 为 $\|P_{V_{\text{eff}}} w^*\|_1^2 / \|P_{V_{\text{eff}}} w^*\|_2^2 = \Theta(r_{\text{eff}})$ (引理 6.2 delocalization 分支)。合并， $P(w^*) = \|w^*\|_1 / \|w^*\|_\Sigma \geq (1 - O(\rho' + \beta + \rho'')) \sqrt{r_{\text{eff}}} / \sqrt{\|\Sigma\|}$ ，在对齐/平/占据/delocalized 极限下取等。失效。大 $\beta \Rightarrow P(w^*) \rightarrow \sqrt{\text{tr} \Sigma^{-1}} \gg \sqrt{r_{\text{eff}}}$ ；大 ρ'' (次梯度泵尾质量)；(EO3) 被违 ($a_\varepsilon|_{V_{\text{eff}}}$ 尖峰) $\Rightarrow$ 解坐落于 $O(1)$ 坐标、 $P(w^*) = O(1)$ 。□

B.14 推论 8.4 (认证半径) 的证明

$R(\varepsilon; w^*) = \Phi(t) = \frac{1}{2}$ 当且仅当 $t = 0$ 当且仅当 $\varepsilon \|w^*\|_1 = \langle w^*, \mu \rangle$ ，即 $\varepsilon_{\text{cert}} = \langle w^*, \mu \rangle / \|w^*\|_1$ 。对 $\varepsilon > \varepsilon_{\text{cert}}$ ， $t > 0$ 、 $R > \frac{1}{2}$ ；在固定二元信道约化下线性判别不携带信息。□

C 最优鲁棒半径

命题 8.5 的证明。设 $F(\varepsilon) := V(\varepsilon) - C(\varepsilon)$ ，故 $F'(\varepsilon) = V'(\varepsilon) - C'(\varepsilon) = K|P'_{\text{breach}}(\varepsilon)| - \lambda_\varepsilon$ 。 (i) **存在性**。 $F'(0^+) = K|P'_{\text{breach}}(0)| - C'(0^+) = K|P'_{\text{breach}}(0)| - \lambda_0$ ；内部极大 $\varepsilon^{**} > 0$ 存在当且仅当 $F'(0^+) > 0$ ，即 $K|P'_{\text{breach}}(0)| > \lambda_0$ 。判据是真实边际成本 $C'(0^+) = \lambda_0 = \lim_{\varepsilon \rightarrow 0^+} \lambda_\varepsilon$ ，它是过自信体制量 ($t(0) \ll 0$ 、 $\phi(t) \rightarrow 0$)、一般 $\ll c_M \sqrt{k_\varepsilon} / \sigma$ ；此处用 margin-density 地板将不正确。 (ii) **唯一性**。 V' 严格递减 (假设 (c))， $C' = \lambda_\varepsilon$ 在相关范围上非减 (边际收紧时价格上升)，故 F' 严格递减、至多一个零点；结合 (i) 恰有一个，且 F 于其处严格凹。 (iii) **边界条件**。在 ε^{**} 处 $F' = 0$ 给 $K|P'_{\text{breach}}(\varepsilon^{**})| = \lambda_\varepsilon(\varepsilon^{**})$ 。 (iv) **比较静态**。对 $F'(\varepsilon^{**}; K, k_\varepsilon) = 0$ 用隐函数定理： $\partial \varepsilon^{**} / \partial K = -F'_K / F'_\varepsilon = |P'_{\text{breach}}| / (-F''_\varepsilon) > 0$ (分子 > 0 、 $F''_\varepsilon < 0$)；并且，经使整条边际成本表上移的外生复杂度参数 π ($\partial \lambda_\varepsilon / \partial \pi > 0$ ，如 $\pi = d$)， $\partial \varepsilon^{**} / \partial \pi = -F'_\pi / F'_\varepsilon < 0$ ， $F'_\pi = -\partial \lambda_\varepsilon / \partial \pi < 0$ ；特别地 $\partial \varepsilon^{**} / \partial d < 0$ 。我们对外生 π 求导，非对内生 $k_\varepsilon = k_\varepsilon(\varepsilon)$ (其非可在改变 ε 时保持固定的自由参数)。 (v) 因 $F'(\varepsilon_{\text{cert}}) \leq 0$ (越过认证半径价值增益消失而成本仍在)， $\varepsilon^{**} \leq \varepsilon_{\text{cert}}$ 。□

D 工程解读

D.1 保险类比

鲁棒边际价可读作保费：保障是对抗半径 ε ，保费是 λ_ε ，赔付是最坏扰动 $\max_\delta \ell(x + \delta, y)$ 。 ℓ_∞ 对手同时压所有坐标，迫使模型对每个有效维度 ($\sqrt{d}$ 或 $\sqrt{r_{\text{eff}}}$) 的赔付预留准备金——这是前因子饱和的直观来源——且一旦 ε 越过认证半径 $\varepsilon_{\text{cert}}$ ，保障 (在信息论意义上) 失效。类比为启发式；严格陈述是正文的次梯度语言。

D.2 维数税作为设计约束

定理 4.1 说明税 $\lambda_\varepsilon \geq c_M \sqrt{k_\varepsilon} / \sigma$ 由 ℓ_∞ / ℓ_1 几何强制、非建模选择：对固定工作点，不能通过改变判别把边际价压到有效支持地板之下，只能通过改变有效支持本身。

D.3 测量配方

廉价代理之桥（命题 8.1、命题 8.2）给出操作配方：在小 ε 处以 $\mathbb{E}\|\nabla_x \ell\|_1$ （一次反向传播）估计鲁棒价，带一个由 κ_∞ 控制的 $O(\varepsilon^2)$ 曲率修正（注 8.3）。

D.4 经有效秩降税

降税的杠杆是有效支持／稳定秩，如 § 8 § 8.5 所述：压缩表示的有效秩把前因子从 $\sqrt{d}$ 降向 $\sqrt{r_{\text{eff}}}$ （以有效占据为条件）。低秩适配与 LLM 解读及其数量级估计见该节。

参考文献

- Philip W. Anderson. Absence of diffusion in certain random lattices. *Physical Review*, 109(5):1492–1505, 1958.
- Mark Bagnoli and Ted Bergstrom. Log-concave probability and its applications. *Economic Theory*, 26(2):445–469, 2005.
- Sébastien Bubeck and Mark Sellke. A universal law of robustness via isoperimetry. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 34, 2021.
- Frank H. Clarke. *Optimization and Nonsmooth Analysis*. Classics in Applied Mathematics. SIAM, 1990.
- John M. Danskin. The theory of max-min, with applications. *SIAM Journal on Applied Mathematics*, 14(4):641–664, 1966.
- Ferdinand Evers and Alexander D. Mirlin. Anderson transitions. *Reviews of Modern Physics*, 80(4):1355–1417, 2008.
- Anthony V. Fiacco. *Introduction to Sensitivity and Stability Analysis in Nonlinear Programming*. Academic Press, 1983.
- Peiran Gao, Eric M. Trautmann, Byron M. Yu, Gopal Santhanam, Stephen I. Ryu, Krishna V. Shenoy, and Surya Ganguli. A theory of multineuronal dimensionality, dynamics and measurement. *bioRxiv*, page 214262, 2017.
- Adel Javanmard and Mahdi Soltanolkotabi. Precise statistical analysis of classification accuracies for adversarial training. *The Annals of Statistics*, 50(4):2127–2156, 2022. [arXiv:2010.11213](#).
- Adel Javanmard, Mahdi Soltanolkotabi, and Babak Hassibi. Precise tradeoffs in adversarial training for linear regression. In *Conference on Learning Theory (COLT)*, volume 125 of PMLR, pages 2034–2078, 2020.

- Yurii Nesterov. Semidefinite relaxation and nonconvex quadratic optimization. *Optimization Methods and Software*, 9(1–3):141–160, 1998.
- R. Tyrrell Rockafellar and Roger J.-B. Wets. *Variational Analysis*. Springer, 1998.
- Fariborz Salehi, Ehsan Abbasi, and Babak Hassibi. The impact of regularization on high-dimensional logistic regression. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 32, pages 12005–12015, 2019.
- Adrien Saumard and Jon A. Wellner. Log-concavity and strong log-concavity: A review. *Statistics Surveys*, 8:45–114, 2014.
- Ludwig Schmidt, Shibani Santurkar, Dimitris Tsipras, Kunal Talwar, and Aleksander Madry. Adversarially robust generalization requires more data. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 31, 2018.
- Hossein Taheri, Ramtin Pedarsani, and Christos Thrampoulidis. Asymptotic behavior of adversarial training in binary classification. In *IEEE International Symposium on Information Theory (ISIT)*, 2022. arXiv:2010.13275.
- Kasimir Tanner, Matteo Vilucchio, Bruno Loureiro, and Florent Krzakala. A high-dimensional model for adversarial training: Geometry and trade-offs. arXiv preprint arXiv:2402.05674, 2024.
- Christos Thrampoulidis, Samet Oymak, and Babak Hassibi. Regularized linear regression: A precise analysis of the estimation error. In *Conference on Learning Theory (COLT)*, volume 40 of PMLR, pages 1683–1709, 2015.
- Dimitris Tsipras, Shibani Santurkar, Logan Engstrom, Alexander Turner, and Aleksander Madry. Robustness may be at odds with accuracy. In *International Conference on Learning Representations (ICLR)*, 2019.
- Franz Wegner. Inverse participation ratio in $2 + \varepsilon$ dimensions. *Zeitschrift für Physik B*, 36(3):209–214, 1980.
- Dong Yin, Kannan Ramchandran, and Peter Bartlett. Rademacher complexity for adversarially robust generalization. In *International Conference on Machine Learning (ICML)*, volume 97 of PMLR, pages 7085–7094, 2019.