

# 对抗鲁棒性的仪表盘： 影子价格的测量、预算与控制

王广宇

billgywang@gmail.com

## Abstract

配套论文 (A 篇) 表明:对抗鲁棒性的边际价——约束价值函数在对抗半径  $\varepsilon$  上的次梯度  $\lambda_\varepsilon = \partial L^*/\partial \varepsilon$ ——存在一个地板,其正确定价单元是鲁棒最优判别的有效支持  $k_\varepsilon = (\|w^*\|_1/\|w^*\|_2)^2$ ,即  $\lambda_\varepsilon \geq c_M \sqrt{k_\varepsilon}/\sigma$ 。该结果说明价格存在;但它本身并不告诉实践者:在自己的模型上价格是多少、该买多少鲁棒性、如何调控训练预算。本文以一个开源工具箱 `shadowprice` 弥合这一缺口,它按三层组织——**测量、决策、控制**——并配一套验证协议。测量层用每批一次反向传播(无对抗内循环)读出价格( $\lambda_\varepsilon \approx \mathbb{E}\|\nabla_x \ell\|_1$ ),给出曲率修正  $\kappa_\infty$  的括号,追踪有效维数  $k_\varepsilon$ ,并在无需逐半径重训的情况下外推价格,准确至一个测量墙(线性模型下精确,一般情形近似)。决策层计算认证半径与经济最优半径  $\varepsilon^{**}$ 。控制层以闭环把预算驱到  $\varepsilon^{**}$ 。我们用闭式对仪表做单元测试(Stage A, 13/13 项检查),在一个小型已训练模型上以真实测量的破损曲线加以演示(Stage A.5),并为大规模深网给出带明确证伪条件的 Stage B 协议。工具箱核心与框架无关;重依赖为可选。

## 1 引言

对抗鲁棒性并非免费,其成本也不是可以一厢情愿绕开的建模细节。A 篇 ([Companion paper \(Paper A\), 2025](#)) 将此精确化:把对抗半径  $\varepsilon$  视为约束价值函数  $L^*(\varepsilon)$  的一维预算,鲁棒边际价即次梯度  $\lambda_\varepsilon = \partial L^*/\partial \varepsilon$ ,并服从一个维数地板

$$\lambda_\varepsilon \geq c_M \frac{\sqrt{k_\varepsilon}}{\sigma}, \quad k_\varepsilon = \left( \frac{\|w^*\|_1}{\|w^*\|_2} \right)^2, \quad (1)$$

其中  $w^*$  是鲁棒最优判别,  $k_\varepsilon$ ——其有效支持,即软阈值 active 支持集的 participation ratio——是真正的定价单元,并特化为  $\sqrt{d}$ (稠密)、 $\sqrt{k}$ (稀疏)、 $\sqrt{r_{\text{eff}}}$ (低有效秩)三个特例。

式 (1) 是一个存在性陈述。对工程师而言,它引出三个它并不回答的运营问题:

1. **测量**。在我的模型上、此刻,  $\lambda_\varepsilon$  是多少,而且这个测量可信吗?
2. **决策**。我该买多少鲁棒性——经济最优半径是多少?
3. **控制**。如何在不重跑一切的情况下,把训练预算调向那个最优点?

本文以一个小巧、经验证、开源的工具箱 `shadowprice` 及配套协议回答这三者。我们的贡献不是新理论——定理都在 A 篇——而是可操作化:一组仪表,每件都系于 A 篇的一个闭式、都有一个廉价估计器、都经过验证。具体地:

- 一个**价格计**,用每批一次反向传播(无对抗内循环)读出  $\lambda_\varepsilon \approx \mathbb{E}\|\nabla_x \ell\|_1$ ,带误差棒与  $\delta^{-3}$  采样预算 (§ 3);
- 一个**曲率预警**  $\kappa_\infty$ ,在一阶价格代理不可信时发出警示 (§ 3);
- 一个**有效支持诊断**  $k_\varepsilon$ ,作为逐样本的有效维数,沿训练追踪 (§ 3);
- 一个**免重训代理**,把价格跨  $\varepsilon$  外推,直至一个测量墙 (§ 3);
- 一套**决策演算**,给出认证半径  $\varepsilon_{\text{cert}}$  与最优半径  $\varepsilon^{**}$  (§ 4);
- 一个**闭环控制器**,把预算驱到  $\varepsilon^{**}$  (§ 5)。

我们在合成线性-高斯模型上对每件仪表用 A 篇闭式加以验证(Stage A, § 8),并为真实网络给出带证伪条件的 Stage B 协议 (§ 8)。库见 § 9。我们相对现有鲁棒性工具生态——它们评测与攻击,但不定价——作出定位 (§ 10)。

## 2 背景:资源-变分原理

本节自足:仪表所依赖的三个闭式在此以数行推出,故本文不依赖 A 篇 (Companion paper (Paper A), 2025) 亦可读(A 篇提供一般理论与地板常数)。对二元高斯混合  $x = y\mu + z$ ,  $z \sim N(0, \sigma^2 I)$ , 以及面对半径  $\varepsilon$  的  $\ell_\infty$  对手的线性判别  $w$ ,鲁棒风险为  $R(\varepsilon; w) = \Phi(t(w))$ ,标准化边际  $t(w) = (\varepsilon\|w\|_1 - \langle w, \mu \rangle) / (\sigma\|w\|_2)$ ,边际价为

$$\lambda_\varepsilon = \frac{\partial R}{\partial \varepsilon} = \frac{\sqrt{k_\varepsilon}}{\sigma} \phi(t), \quad k_\varepsilon = (\|w\|_1 / \|w\|_2)^2. \quad (2)$$

推导 (自足)。三个闭式皆出自一次计算。**(a) 风险。**半径  $\varepsilon$  的最坏  $\ell_\infty$  扰动把干净边际  $y\langle w, x \rangle$  平移其支撑函数  $-\varepsilon\|w\|_1$  ( $\ell_\infty$  球的  $\ell_1$  对偶,在  $\delta = -\varepsilon y \text{sign}(w)$  处取得)。误分类当  $\langle w, \mu \rangle + y\langle w, z \rangle < \varepsilon\|w\|_1$ ; 因  $y\langle w, z \rangle \sim N(0, \sigma^2\|w\|_2^2)$ ,此概率为  $\Phi(t(w))$ 。**(b) 价格。**对  $\varepsilon$  求导  $R = \Phi(t)$  (其中  $\partial t / \partial \varepsilon = \|w\|_1 / (\sigma\|w\|_2)$ ) 即得 (2),前因子恰为  $\|w\|_1 / \|w\|_2 = \sqrt{k_\varepsilon}$ 。**(c) 软阈值最优。**在  $\|w\|_2 = 1$  上极小化  $t(w)$  即  $\min_w \varepsilon\|w\|_1 - \langle w, \mu \rangle$ ; 对齐符号 ( $\text{sign } w_i = \text{sign } \mu_i$ ) 并在正卦限球面上极大化该线性泛函,得  $w_i^* \propto \text{sign}(\mu_i)(|\mu_i| - \varepsilon)_+$ ——软阈值,其 active 集的 participation ratio 即  $k_\varepsilon$ 。一般(非高斯、对数凹)版本以 margin 密度  $p_S$  取代  $\phi$ ,在 A 篇证明;工具箱只用到这三行加上该密度推广。三个事实随之驱动工具箱。**(i) 定价单元是  $k_\varepsilon$ :**  $\ell_\infty$  攻击诱导  $\ell_1$  对偶几何,其前因子  $\|w\|_1 / \|w\|_2 = \sqrt{k_\varepsilon}$  即被课税的有效维数。**(ii) 一个廉价代理:**当  $\varepsilon \rightarrow 0, \lambda_\varepsilon \rightarrow \mathbb{E}\|\nabla_x \ell\|_1$ ,由一次反向传播得,有限- $\varepsilon$  修正由  $\ell_\infty$  曲率  $\kappa_\infty(x) = \max_{s \in \{\pm 1\}^d} |s^\top \nabla^2 f(x) s|$  经  $|\lambda_\varepsilon - \hat{\lambda}_\varepsilon| \leq \varepsilon \mathbb{E}[\kappa_\infty] + O(\varepsilon^2)$  控制。**(iii) 地板在 margin-density 窗口  $|t| \leq M$  内成立,**其中  $\phi(t) \geq \phi(M) =: c_M$ ;窗口之外(过自信体制,  $|t|$  大)价格可忽略,测量进入尾部。这三个事实分别成为有效支持诊断、价格计、曲率/坍塌检查。

**训练-推理之桥。**第四个事实使工具箱跨训练/部署边界保持连贯。A 篇的读出算子表明:训练侧协态(价值对训练控制的敏感度)与部署侧鲁棒价是同一次梯度对象  $\partial L^*$  的两种读出——“换轴,不换机器”。操作上这意味着训练期测得的一个量(输入梯度对偶范数)可预测部署价,至一个  $O(\varepsilon)$  曲率项。这正是以下之所以成立的依据:(i) 免重训代理——测量一次并外推;(ii) 训练-推理边际差作为一致性可观测(O6):其大小恰为  $\varepsilon \mathbb{E}[\kappa_\infty]$  修正,故大于曲率界的差意味着测量出错,而非真实的训练/部署差异。

自 A 篇导入的假设。工具箱继承(不再证明)五项结果/条件;一旦它们失效,对应仪表即无保证。(A1)  $\sqrt{k_\varepsilon}$  价格地板及其常数(A 篇定理 4.1);(A2) 对称对数凹噪声下的 margin 密度推广  $\lambda_\varepsilon = (\sqrt{k_\varepsilon}/\sigma) p_S(t)$ (坍缩检查在非高斯情形所用);(A3) 包络/Danskin 正则性——价值函数次梯度几乎处处单值,故价格良定义;(A4)  $C^2$  分类器的局部线性化有效性,即价格经  $w = \nabla f(x_0)$  在  $\kappa_\infty$  界定的邻域内传递(非全局);(A5) 命题 8.4 的约化型部署经济学—— $P_{\text{breach}}$  外生、单调、由威胁模型提供。A1–A3 在 A 篇证明;A4–A5 是本文采用并仅在 Stage A.5 经验测试的建模选择。

### 3 仪表盘 (测量)

测量层把上述闭式变成廉价、经验证的读数。全程库暴露一个框架无关核心:估计器接受用户提供的  $\text{grad\_fn}(x) \rightarrow \nabla_x \ell$  以及(可选的)  $\text{risk\_fn}(\text{eps}) \rightarrow R$ ,故 numpy、PyTorch、JAX 皆可用。

**仪表 1:价格计。** 式 (2) 的主项是梯度范数代理  $\hat{\lambda}_\varepsilon = \mathbb{E} \|\nabla_x \ell\|_1$ ,每批一次反向传播(无对抗内循环);该估计仍需一批样本以得稳定均值,由其 bootstrap 置信区间量化。库对一批求平均并返回 bootstrap 误差棒(`price_gradnorm`)。若需直接的有限- $\varepsilon$  读数,则以中心差分对蒙特卡洛风险求导(`price_finite_diff`)。因该风险本身是采样的,导数估计有偏差  $\sim h^2$ 、方差  $\sim \sigma^2/(nh^2)$ ;二者平衡给出特征性的  $\delta^{-3}$  预算——要达到导数精度  $\delta$  需  $n \sim \delta^{-3}$  个样本——由 `fd_budget` 给出。图 1(a) 显示有限差分价格计与闭式 (2) 吻合至机器精度。

**Cookbook.**用一次反传代理做连续监控(每几百步一次,基本免费),用有限差分价格计做定期真值核对。把批量取到 bootstrap 置信区间足够窄——经验法则:在据某读数行动前,让 95% 区间窄于均值的 10%;输入梯度  $\ell_1$  范数集中很快,几百个样本通常够。做有限差分时,用 `fd_budget` 定步长而非猜测:追求极小精度  $\delta$  代价高( $n \sim \delta^{-3}$ ),故取决策能容忍的最松  $\delta$ 。最常见的陷阱是在过自信体制测量:若  $|t|$  大,价格确实近零,读数虽正确却无信息——在信任一个小价格前,先确认落在 margin-density 窗口 ( $|t| \lesssim M$ ,如鲁棒精度远离 0 与 1)。

**仪表 2:曲率预警。** 一阶代理只在  $O(\varepsilon)$  曲率修正小处可信。精确算  $\kappa_\infty$  是布尔二次规划,但此桥只需一个可计算的上界。库提供无依赖的界  $\sum_{ij} |H_{ij}|$ ,并在有 `cvxpy` 时提供更紧的 SDP 松弛  $\max \langle H, X \rangle$  s.t.  $X \succeq 0$ ,  $\text{diag}(X) = 1$ (取双侧符号,故界住  $\max |s^\top H s|$ ),并配一个随机符号下界 (`kappa_infty`)。上/下括号比大即为预警信号,提示当前  $\varepsilon$  下代理可能不可靠。

**Cookbook.**别每步都算  $\kappa_\infty$ ——SDP 有  $O(d^2)$  个变量,是给定期审计用的。连续监控用无依赖的  $\sum_{ij} |H_{ij}|$  界(大  $d$  用 Hutchinson 迹估计),SDP 留作偶尔收紧。把括号当红绿灯读:比接近 1 表示一阶代理可信、可在当前  $\varepsilon$  定价;比  $\gg 1$  则要么缩小  $\varepsilon$  直到  $O(\varepsilon)$  修正可忽略,要么退回有限差分价格计。对 ReLU 网络 Hessian 几乎处处为零、曲率集中在激活边界;从跨最近边界的梯度跳变估计  $\kappa_\infty$ (A 篇 ReLU 注),而非从谱范数。一个实用默认:每当坍缩残差(仪表 4)漂移就审计  $\kappa_\infty$ ,因曲率是使其膨胀的因素之一。

**仪表 3:有效支持诊断。** 输入梯度的定价单元  $k_\varepsilon = (\|w\|_1/\|w\|_2)^2$  是一个廉价的逐样本有效维数,取值于  $[1, d]$ :localized 梯度为 1,完全 delocalized 为  $d$ (`participation_ratio`)。沿训练追踪 (`SupportTracker`),它揭示维数税如何演化。图 1(b) 显示软阈值判别的  $k_\varepsilon$  随  $\varepsilon$  增大、坐标退出而收缩。

**Cookbook.**把比值  $k_\varepsilon/d$  沿训练追踪,作为有效维数的健康度(SupportTracker 记录每批均值与 10/90 分位)。看趋势而非瞬值: $k_\varepsilon/d \rightarrow 1$  表示输入梯度完全 delocalized、你在付全额  $\sqrt{d}$  税; $k_\varepsilon/d \ll 1$  表示模型把敏感度集中在少数坐标——税更低,但要核实这是真的低有效秩,而非对少数特征的脆弱依赖(与价格、与留出鲁棒性交叉核对)。一个有用的合理性检查: $\sqrt{k_\varepsilon}$  应能预测测得的价格因子  $\lambda_\varepsilon \sigma / \phi(t)$ (仪表 4);持续不匹配意味着梯度 participation ratio 并非有效定价单元,这本身即诊断(如强特征协方差/相干,A 篇)。

**仪表 4:无量纲坍缩检查。** 一般而言(A 篇的对数凹地板,不止高斯情形),价格分解为  $\lambda_\varepsilon = (\sqrt{k_\varepsilon}/\sigma) p_S(t)$ ,其中  $p_S$  是标准化边际  $t = y\langle w, x \rangle / (\sigma \|w\|_2)$  的密度;高斯  $\phi$  只是线性模型特例。残差

$$\rho_{\text{collapse}} = |\lambda_\varepsilon \sigma / p_S(t) - \sqrt{k_\varepsilon}| / \sqrt{k_\varepsilon} \quad (3)$$

是一个标度不变性自检:测量落在验证体制内时  $\approx 0$ ,否则膨胀。在真实网络中估计  $p_S$ 。真实模型没有闭式  $\phi$ ,故  $p_S$  由经验估计:收集逐样本边际(logit 间隙  $yf(x)$ ,或标准化的  $t$ ),在一批上作核密度估计(`estimate_margin_density`)。等价地,因  $\ell_\infty$  攻击把每个边际平移  $\varepsilon \|\nabla_x f\|_1$ ,价格满足  $\lambda_\varepsilon \approx \bar{g} p_M(\varepsilon \bar{g})$ ,其中  $\bar{g} = \mathbb{E} \|\nabla_x f\|_1$ 、 $p_M$  是原始边际的 KDE——这是 (3) 的完全模型无关形式,无需分布假设。在 § 7 的已训练 MLP 上,该经验预测与测得价格相差约 30% 以内(中位,in-regime),残差反映线性模型所无的梯度-边际异质性。它除模型自身读数外不需任何真值,是 Stage-A 协议的可观测 O3。

**Cookbook.**把坍缩残差作为常开的一致性监视器——它是判断你的任何价格读数是否可信的最廉价方式,因为它把价格计、有效支持诊断与工作点对一个闭式恒等式交叉核对。残差低于  $\sim 5\%$  为健康——当闭式适用时(线性/高斯体制);在真实网络上用经验 KDE 边际密度时固有限制更高,故  $\sim 30\text{--}40\%$  才是健康区间(表 1)。要紧的是趋势:残差远超其体制下限即是一个在你的价格出错前就跳闸的开关,并能定位故障:它在你离开 margin-density 窗口(过自信  $|t|$ )、曲率大(审计  $\kappa_\infty$ )、或噪声远离对数凹(恒等式的假设)时膨胀。把膨胀的残差当停牌信号:在据  $\varepsilon^{**}$  或控制器行动前,先复位体制。

**仪表 5:免重训代理。** 在目标半径估计  $\lambda_\varepsilon$  通常需要一个在该  $\varepsilon$  处重训的模型。免重训代理避开这点:它测量输入梯度几何一次(单批反向传播,无逐半径鲁棒重训),并用  $w^*$  的软阈值结构把价格跨  $\varepsilon$  外推, $w(\varepsilon) \approx \text{soft}_\varepsilon(w_0)$ 、 $\lambda_\varepsilon \approx (\sqrt{k_\varepsilon(w(\varepsilon))}/\sigma) \phi(t(\varepsilon))$ (RetrainFreeProxy)。该外推在线性模型下精确、一般情形近似;当 active 支持稳定且工作点留在 margin-density 窗口内时可靠,越过测量墙——支持坍缩或  $|t|$  离开窗口的半径——即失效。代理会标记墙外的点(图 2b)。

**Cookbook.**在一个廉价工作点标定一次(单次干净模型反传),然后无需重训读出整条  $\lambda_\varepsilon$  曲线——这正是预算得以廉价的原因。尊重墙:绝不据被标 `beyond_wall` 的外推行动;越过它就付一次真实鲁棒探测的代价。按风险容忍度设两个墙旋钮: $M$ (margin-density 半宽)守尾部体制,`min_active_frac` 守支持坍缩——若错误价格代价高就收紧,愿担风险外推更远就放松。模型有实质变化(训练相变、微调、分布漂移)时就重标定,因代理继承其被测快照的几何。实际中墙落在存活支持变得噪声敏感处,故梯度测量的 bootstrap 置信区间变宽是墙将近的早期提示。

## 4 决策演算 (决策)

测量供给决策。两个半径要紧。认证半径  $\varepsilon_{\text{cert}} = \langle w^*, \mu \rangle / \|w^*\|_1(\text{cert\_radius})$  是鲁棒风险达到  $\frac{1}{2}$  之处;越过它分类器劣于随机,在固定二元信道约化下不携带信息。最优鲁棒半径  $\varepsilon^{**}$  回答”






Figure 1: A 篇线性-高斯模型上的仪表盘。(a) 有限差分价格计(点)与闭式  $(\sqrt{k_\epsilon}/\sigma)\phi(t)$ (线)吻合至机器精度(平均  $|\cdot| \approx 10^{-13}$ )。 (b) 软阈值判别的<sup>有效支持</sup>  $k_\epsilon(\epsilon)$  随坐标退出从  $\sim 160$  收缩向小值 ( $d = 200$ )。 (c) 决策演算:净值  $V - C$  与内部最优半径  $\epsilon^{**}$ 。

买多少”。给定部署价值  $V(\epsilon) = K(1 - P_{\text{breach}}(\epsilon))$  ( $K$  为单次失陷损失)与鲁棒成本  $C(\epsilon) = \int_0^\epsilon \lambda_{\epsilon'} d\epsilon'$  (其边际即影子价格),  $\epsilon^{**} = \arg \max_\epsilon [V - C]$  满足一阶条件

$$K |P'_{\text{breach}}(\epsilon^{**})| = \lambda_\epsilon(\epsilon^{**}), \quad (4)$$

即边际部署收益等于边际鲁棒价。内部最优存在当且仅当  $K|P'_{\text{breach}}(0)| > \lambda_0$  (在  $0^+$  处的真实边际成本,一个过自信体制量,而非 margin-density 窗口界),唯一,且  $\epsilon^{**} \leq \epsilon_{\text{cert}}$ 。求解器 `optimal_radius` 对一阶条件 (4) 括号求根;图 1(c) 给出一个内部  $\epsilon^{**}$ 。此读法是保险式的:保障是  $\epsilon$ , 保费是  $\lambda_\epsilon$ , 买鲁棒性直到边际保费等于期望失陷损失的边际下降。

**拟合  $P_{\text{breach}}$  (具体示例)。** 破损模型并非假设——它由若干红队点拟合。给定若干半径处的攻击成功率(如来自 AutoAttack), `fit_breach_model` 返回一个光滑的  $P_{\text{breach}}$  及其导数,直接喂给求解器:

```
# red-team evaluations: attack success (breach prob) at several radii
eps_pts = [0.0, 0.05, 0.1, 0.2, 0.3, 0.5]
successes = [0.90, 0.74, 0.58, 0.36, 0.21, 0.09]
fit = fit_breach_model(eps_pts, successes, family="logistic") # rmse ~ 0.04
res = optimal_radius(price_fn, fit["Pbreach"], K=2.0, eps_max=eps_cert,
                    Pbreach_prime=fit["Pbreach_prime"])
res.eps_star # -> the budget to train to
```

拟合对函数形式稳健(logistic 或 exponential);只有单调性与 0 附近斜率影响内部  $\epsilon^{**}$  的存在性。图 4 在已训练 MLP 上正是运行这一流程。

**$\epsilon^{**}$  何时可信?一份起飞前清单。** 决策演算只与其价格与破损输入一样可靠。据  $\epsilon^{**}$  行动前,核对表 1 的各道闸门;任一失败,该数即不可信,且故障已被定位。这把各仪表的 cookbook 汇成一道总闸。

| 闸门（须成立）                                                                                | 若失败                                              |
|----------------------------------------------------------------------------------------|--------------------------------------------------|
| 工作点在 margin-density 窗口 ( $ t  \lesssim M$ ; 鲁棒精度远离 0, 1)                               | 价格在尾部/过自信体制; 读数无信息——移动工作点                        |
| 坍塌残差低于其体制下限 ( $\lesssim 5\%$ 闭式, $\lesssim 30\text{--}40\%$ 经验 KDE)                    | 价格计、 $k_\epsilon$ 、工作点不一致——不要定价                  |
| 目标 $\epsilon$ 处曲率括号紧 ( $\kappa_\infty^\uparrow / \kappa_\infty^\downarrow \approx 1$ ) | 一阶代理不可靠——缩小 $\epsilon$ 或用有限差分                    |
| 价格置信区间窄 (95% 宽 $\lesssim 10\%$ 均值)                                                     | 采样不足——增大批量 (§ 3)                                 |
| 破损曲线单调递减且 $K P'_{\text{breach}}(0)  > \lambda_0$                                       | 无内部最优(角点); 鲁棒性不值得买, 或买到 $\epsilon_{\text{cert}}$ |
| 外推位于测量墙以内                                                                              | 在信任价格表前重标定免重训代理                                  |

Table 1: 决策演算的可靠性清单。全闸绿灯  $\Rightarrow \epsilon^{**}$  可信; 任一红灯定位故障。坍塌残差(第 2 行)带一个依体制的阈值 (§ 7)。

**Cookbook.** 你必须提供的两个输入是  $P_{\text{breach}}(\epsilon)$  与  $K$ 。从你的部署威胁模型估计  $P_{\text{breach}}$ ——若干半径处的红队成功率, 或历史事件频率——并拟合一条光滑递减曲线; 结果对其确切形状不敏感(只有单调性与 0 处斜率对存在性要紧)。把  $K$  设为单次失陷的实际成本(以你的价值函数所用单位: 金钱、声誉、宕机)。然后把结果读作决策: 内部  $\epsilon^{**}$  就是你的预算; 0 处角点意味对此威胁模型不值得买鲁棒性(即便  $\epsilon \rightarrow 0$  边际保费也超过边际收益);  $\epsilon_{\text{cert}}$  处角点意味一路买到认证极限。把比较静态当规划工具:  $\epsilon^{**}$  随模型复杂度( $d$  或  $r_{\text{eff}}$ ) 升高而降低, 量化了”更大的模型经济上更难鲁棒化”的说法。把价格计测得的价格(而非 population 地板)喂给求解器, 使预算反映你的真实模型。

## 5 闭环资源控制（控制）

决策供给控制。控制器不离线解 (4), 而是仅用测得价格  $\lambda_\epsilon$  与部署边际收益  $K|P'_{\text{breach}}(\epsilon)|$ , 在线把训练期预算驱到  $\epsilon^{**}$ :

$$\epsilon_{t+1} = \text{clip}(\epsilon_t + \eta F'(\epsilon_t), 0, \epsilon_{\text{max}}), \quad F'(\epsilon) = K|P'_{\text{breach}}(\epsilon)| - \lambda_\epsilon. \quad (5)$$

因净值在相关范围内严格凹,  $F'$  严格递减, 阻尼不动点迭代收敛到  $\epsilon^{**}$  (亦提供阻尼-Newton 变体)。控制器(BudgetController)不在每个候选半径重训——它消费测得价格。图 2(a) 显示从三个初值收敛到同一  $\epsilon^{**}$ , 与离线求解器一致。

**Cookbook.** 增益  $\eta$  从小起, 增大到收敛快而不振荡; 若  $F'$  光滑, 阻尼-Newton 模式数步即达  $\epsilon^{**}$ 。始终夹到  $[0, \epsilon_{\text{cert}}]$ ——没有理由花过认证极限。用价格计(仪表 1)测得的价格驱动回路, 并以坍塌残差(仪表 4)设闸: 若残差跳闸, 冻结控制器直至体制复位, 因误测的价格会把预算引偏。以一阶残差  $|F'(\epsilon)|$  判定收敛, 而非仅凭步长。何时用控制器而非一次性求解器: 静态部署决策用求解器, 而当价格表在训练中漂移(特征学习重塑  $k_\epsilon$ 、从而  $\lambda_\epsilon$ )、目标  $\epsilon^{**}$  本身在移动时, 用控制器。

## 6 范例: 从测量到预算

仪表可组合成一条简短工作流。设一支团队要把一个分类器部署于  $\ell_\infty$  威胁下, 须决定训练鲁棒预算。此过程分四步, 每步一件仪表, 并与 § 8 的验证相对应。

第 1 步——测量并验信。用一次反向传播读出当前工作点的价格  $\hat{\lambda}_\epsilon = \mathbb{E}\|\nabla_x \ell\|_1$  及其 bootstrap 置信区间(仪表 1)。在相信它之前, 先跑两道守卫: 确认工作点在 margin-density 窗口(鲁棒




Figure 2: 控制与免重训测量(Stage A)。(a) 闭环控制器 (5) 从三个初值把预算驱到  $\varepsilon^{**} = 1.13$ , 与离线 `optimal_radius` 求解器一致。(b) 免重训代理在有噪声单次梯度测量下, 于测量墙( $\varepsilon \approx 1.14$ ) 以内以  $\sim 2\%$  重现真实(重训)价格, 并在越墙发散时被正确标记(叉)。

精度远离 0 与 1), 并检查无量纲坍塌残差(仪表 4) 小——若小, 则价格计、有效支持与工作点相互一致, 价格可信。在 § 8 的合成模型上残差约  $10^{-6}$ ; 真实模型上可接受, 比如  $< 5\%$ 。

第 2 步——定位体制。读有效支持  $k_\varepsilon$  (仪表 3): 其相对  $d$  的值告诉你在付哪种税( $\sqrt{d}$ 、 $\sqrt{k}$  或  $\sqrt{r_{\text{eff}}}$ ), 沿训练追踪则告诉你特征学习是在收缩还是 delocalize 梯度。若需有限- $\varepsilon$  价格而非  $\varepsilon \rightarrow 0$  代理, 则给曲率  $\kappa_\infty$  加括号(仪表 2); 紧括号认证代理, 宽括号表示缩小  $\varepsilon$  或作有限差分。

第 3 步——廉价外推。不必在每个候选半径重训鲁棒模型, 标定免重训代理一次(仪表 5), 读出直至测量墙的整条  $\lambda_\varepsilon$  曲线。这正是使下一步可负担的原因: 决策演算需要的是价格表, 而非单点。

第 4 步——预算并操控。提供部署破损模型  $P_{\text{breach}}$  与单次失陷损失  $K$ , 解出  $\varepsilon^{**}$  (§ 4); 若价格表在训练中漂移, 把同样测得的价格交给控制器 (§ 5) 在线追踪移动的最优。输出是一个可辩护的数字——”训练到半径  $\varepsilon^{**}$ ”——并带审计轨迹: 设定它的价格、测量所处体制、以及为其估值的破损模型。

整条工作流是四次廉价读数加一次求根; 全程不需鲁棒扫描, 且每步都带一个在答案出错前跳闸的自检。

**与攻击套件组合（一条具体流水线）。** `shadowprice` 不攻击也不评测; 它消费那些做这些事的工具的输出。一条具体的端到端流水线: (1) 在若干半径运行 `AutoAttack` (Croce and Hein, 2020) (或 `RobustBench` (Croce et al., 2021) 评测) 得到经验鲁棒精度——即破损曲线  $\{(\varepsilon_i, \text{success}_i)\}$ ; (2) 用 `fit_breach_model` 拟合得光滑  $P_{\text{breach}}$  (第 4 步); (3) 用价格计读边际价; (4) 解  $\varepsilon^{**}$  并用控制器操控。攻击套件回答”模型在半径  $\varepsilon$  处有多鲁棒”; `shadowprice` 把该评测转为”鲁棒性花多少、该买多少”。二者是同一工作流的互补层——评测供给定价——而非竞争者; § 7 在一个已训练网络上正是运行这条流水线(以 PGD 代 `AutoAttack`)。




Figure 3: 已训练 MLP 上的仪表盘(留出测量)。左上:价格代理  $\mathbb{E}\|\nabla_x \ell\|_1$  随模型学习而下降(测试精度上升,虚线)。右上:有效支持  $k_\varepsilon$  于  $(1, d)$  内演化,  $d = 40$ 。左下:来自真实(有限差分)输入 Hessian 的曲率括号  $\kappa_\infty$ ——非零,不同于线性模型(O5)。右下:有限差分 PGD 价格在一阶邻域内落在  $\varepsilon \rightarrow 0$  代理的  $\pm \varepsilon \mathbb{E}[\kappa_\infty]$  曲率带内(O6),印证训练-推理之桥;残差为有限样本 PGD 噪声。

## 7 Stage A.5:一个小型已训练网络

在闭式检查(Stage A)与大规模深网(Stage B)之间,坐落一个中间证据层,我们称之为 Stage A.5:一个真实、已训练、非线性、但小到可在 CPU 上精确运行并完整插装的模型。我们在一个真实已训练非线性模型上运行仪表盘:单隐层 MLP(纯 numpy,  $d = 40$ , 8 个隐单元),以带权重衰减的梯度下降在低 SNR 二分类任务上训练,所有仪表在留出测试集上测量,使工作点留在 margin-density 窗口(测试精度  $\approx 0.76$ , 未插值)。一切使用模型真实输入梯度与有限差分输入 Hessian——无闭式。这是小型 CPU 模型,非大规模深网(见证据层级,表 3);它是合成验证之上诚实的下一级,并填上线性模型上平凡为零的两个可观测(O5 曲率, O6 差)。

**有限差分 PGD 价格,精确定义。** 在非线性模型上”真”价格无闭式,故我们定义一个可测参照。设  $R_{\text{PGD}}(\varepsilon)$  为模型在半径  $\varepsilon$  的  $k$  步  $\ell_\infty$  PGD 攻击下的 0/1 鲁棒误差(此处  $k = 15$ , 步长  $2.5\varepsilon/k$ , 无 restart, 在  $n = 2000$  个留出点上评估)。有限差分 PGD 价格为中心差分

$$\hat{\lambda}_\varepsilon^{\text{PGD}} = \frac{R_{\text{PGD}}(\varepsilon + h) - R_{\text{PGD}}(\varepsilon - h)}{2h}, \quad h = 0.02.$$

两点使比较诚实:(a) PGD 欠攻击,故  $R_{\text{PGD}} \leq R$ 、 $\hat{\lambda}^{\text{PGD}}$  是真实价格的下估计(更强套件如 AutoAttack 会收紧它);(b)  $R_{\text{PGD}}$  是蒙特卡洛 0/1 平均,故该差分带噪声  $\propto \sqrt{p(1-p)/n}/h$ , 在最小半径处主导 O6 残差。代理  $\mathbb{E}\|\nabla_x \ell\|_1$  是独立的  $\varepsilon \rightarrow 0$  估计;O6 检查二者在  $\varepsilon \mathbb{E}[\kappa_\infty]$  曲率带内一致。






Figure 4: 在已训练 MLP 上以真实测量的破损曲线做预算。(a) 在一个带鲁棒性-精度权衡的任务上(一个鲁棒特征加若干非鲁棒特征,Tsipras 式),我们在七个半径对抗训练 MLP,并测量其在固定评估攻击下的破损率  $P_{\text{breach}}(\varepsilon_{\text{train}})$  ( $0.70 \rightarrow 0.41$ , logistic 拟合 rmse 0.13) 及其成本——干净误差的增量 ( $0.01 \rightarrow 0.03$ )——而非合成曲线。(b) 把测得的破损与成本曲线喂给决策演算,最优预算与测得破损极小值重合 ( $\varepsilon^{**} \approx 0.30$ , 此处为边界,因该任务上鲁棒性廉价),控制器收敛于此。因  $\varepsilon^{**}$  在边界,内部噪声鲁棒性数字 (§ 8) 改在 Stage-A 最优上报告。

|       | 测量模型 (仪表盘)                                 |      | 预算模型 (破损曲线)                 |
|-------|--------------------------------------------|------|-----------------------------|
| 架构    | MLP, $d=40$ , 1 隐层 ( $h=8$ ), ReLU         | 任务   | 鲁棒 + 38 非鲁棒特征               |
| 任务    | 高斯混合, 噪声 $\sigma=8$ (低 SNR)                | 架构   | MLP, $h=16$                 |
| 训练/测试 | 2000/2000, 留出测量                            | 对抗训练 | PGD 7 步, 半径 0–0.3 (7 模型)    |
| 优化器   | GD, lr 0.15, wd $5 \times 10^{-3}$ , 360 步 | 评估攻击 | PGD 15 步于 $\varepsilon=0.5$ |
| 随机种子  | 训练 1, 测试 2, 模型 0                           | 测量   | $P_{\text{breach}}$ 、干净误差成本 |

Table 2: Stage A.5 可复现性。两个模型皆为纯 numpy; 脚本 `demo_mlp_training.py` (仪表盘 + 预算) 与 `demo_end_to_end.py` (轨迹) 确定性地重生所有数字。硬件: 单核 Intel Xeon @ 2.10 GHz, numpy 2.4; 墙钟  $\approx 19$  s (仪表盘 + 预算, 含 7 次对抗训练) 与  $\approx 26$  s (基准, 附录 B)。

图 3 显示四件就绪仪表沿训练的表现。三点发现。(i) 价格代理与有效支持如理论所料: 模型拟合时输入梯度价格下降,  $k_\varepsilon$  保持为  $(1, d)$  内的真实有效维数。(ii) 曲率  $\kappa_\infty$  现在非零 (真实 Hessian), 一次反传代理与有限差分 PGD 价格之间的训练-推理差 (O6) 在一阶邻域内落在  $\varepsilon \mathbb{E}[\kappa_\infty]$  带内——§ 2 之桥在真实模型上成立, 至有限样本噪声。(iii) 经验 margin 密度恒等式 (仪表 4) 仅用模型自身边际的 KDE——无高斯假设——即以 bootstrap 中位残差  $\sim 17\%$  (IQR 7–24%, 60 次重采样) 预测测得价格, 在闭式之外演示坍塌检查。这在恰当阈值之内: 紧的  $\approx 5\%$  目标只在闭式使恒等式精确处适用 (Stage A); 经验 KDE 形式因有限样本密度估计与梯度-边际异质性而固有限下更高, 其健康区间为较松的  $\approx 30\text{--}40\%$  (表 1)。此处残差是通过的自检, 而非失败。

图 4 在已训练模型上以真实测量的破损曲线运行 § 6 的完整决策流水线。在上文的干净高斯任务上, 对抗训练无法以精度换鲁棒性——Bayes 分类器已然鲁棒——故我们用一个带真实鲁棒性-精度权衡的任务 (一个鲁棒特征加许多非鲁棒特征), 在七个半径对抗训练 MLP, 并测量  $P_{\text{breach}}(\varepsilon_{\text{train}})$  ( $0.70 \rightarrow 0.41$ ) 及其成本——干净误差增量 ( $0.01 \rightarrow 0.03$ )。把这些测得曲线喂给演算, 最优预算落在测得破损极小值 ( $\varepsilon^{**} \approx 0.30$ ), 由控制器达到。这是在一个真实 (虽小) 网络上、无任何合成输入的 测量  $\rightarrow$  决策  $\rightarrow$  控制 全环。端到端轨迹 (真实输出) 见清单 1。

| 层级       | 模型                          | 建立                      | 不建立          |
|----------|-----------------------------|-------------------------|--------------|
| A(已完成)   | 线性-高斯,闭式                    | 估计器正确(13/13 精确检查)       | 向非线性/真实模型的迁移 |
| A.5(已完成) | 小型已训练 MLP(CPU)              | 仪表在真实模型上运行且自治;O5/O6 被填上 | 深网规模行为       |
| B(已规定)   | 深网 + AutoAttack/RobustBench | (待测)真实规模精度与证伪检查         | ——(此处未跑)     |

Table 3: 证据层级。本文交付 Stage A 与 A.5,并规定 Stage B (§ 8,下附协议)及一个可运行模板 (torch\_resnet\_pricing.py)。

Listing 1: numpy MLP 上的端到端轨迹 (demo\_end\_to\_end.py 的逐字输出;无一数字为杜撰)。

```
[model] held-out test accuracy = 0.763 (in margin-density regime)
[measure] price proxy E||grad_x loss||_1 = 0.639 (95% CI [0.602,0.674])
[measure] effective support k_eps = 23.6 / d=40
[measure] curvature bracket kappa_inf = [0.410, 0.410] (ratio 1.00; trustworthy)
[decide] measured breach P_breach(eps_train) = 0.70 -> 0.41 (7 adv-trained models);
         fit rmse 0.133
[decide] optimal robustness budget eps** = 0.300
[control] closed-loop controller -> 0.300
```

## 8 验证

我们区分三级证据,并明确各自建立与不建立什么(表 3)。**Stage A** 是闭式验证:在线性-高斯模型上每件仪表对着一个精确公式核对——这建立估计器正确,而非它们能迁移。**Stage A.5**(§ 7)是一个小型已训练非线性模型:真实梯度、真实 Hessian、in-regime 工作点——这建立仪表在真实模型上运行且自治,在 CPU 规模,但非深网规模。**Stage B** 是强攻击套件下的大规模深网:带证伪条件与可运行模板加以规定,但此处未执行。

**Stage A (合成,已完成)**。 在一切量皆有闭式的线性-高斯模型上,每件仪表都匹配其 A 篇预测。有限差分价格计与 (2) 吻合至  $\sim 10^{-13}$ (图 1a);曲率括号对小  $d$  的暴力布尔极大值加以验证,SDP 界比平凡界更紧;控制器从两侧到达求解器的  $\varepsilon^{**}$ (图 2a),且在注入价格噪声下紧贴内部最优  $\varepsilon^{**}=1.13$ ;尾部平均  $|\varepsilon - \varepsilon^{**}|$  在 5%、15%、30% 乘性噪声下分别为 0.0007、0.0023、0.0051(即便 30% 噪声也  $< 0.5\%$  相对);免重训代理在墙内重现重训价格(图 2b);六个 Stage-A 可观测——价格、 $k_\varepsilon$ 、坍塌残差 (3)、 $\varepsilon_{\text{cert}}$ 、曲率比、训练-推理差——皆如预期,无量纲坍塌残差全程  $\sim 10^{-6}$ (图 5)。全部检查以自动化套件交付(13/13 通过),列于表 7。

**估计器成本与保证。** 表 4 概括每件仪表的成本与所带保证——实践者两者都需知道。表 8 报告实测墙钟(图 6):梯度类仪表与有效支持基本免费( $d=1000$  也  $< 1$  ms),认证/预算求解  $O(1)$ ,廉价曲率界  $O(d^2)$ ,唯 SDP 曲率界昂贵( $O(d^3)$ ,  $d=200$  需数秒)——坐实它是审计工具,而非逐步监视器。

| 仪表                                            | 成本（梯度之外）        | $d$ -scaling | 保证                                                                     |
|-----------------------------------------------|-----------------|--------------|------------------------------------------------------------------------|
| 价格代理 $\mathbb{E}\ \nabla_x \ell\ _1$          | 每批 1 次反传        | $O(bd)$      | $\varepsilon \rightarrow 0$ 精确; 有限 $\varepsilon$ 处 $O(\varepsilon)$ 误差 |
| 有限差分价格                                        | $2 \times$ 风险评估 | $O(1)$       | 无偏 + $O(h^2)$ 偏差, $\delta^{-3}$ 预算                                     |
| $k_\varepsilon$ (participation ratio)         | 逐元素             | $O(bd)$      | 精确                                                                     |
| $\kappa_\infty$ (绝对值界)                        | $\sum  H_{ij} $ | $O(d^2)$     | 有效上界                                                                   |
| $\kappa_\infty$ (SDP)                         | 凸 SDP           | $O(d^3)$     | 更紧上界(审计)                                                               |
| $\kappa_\infty$ (采样)                          | 随机符号 + 1-opt    | $O(d^2 n_s)$ | 有效下界                                                                   |
| $\varepsilon_{\text{cert}}, \varepsilon^{**}$ | 闭式 / 一维求根       | $O(1)$       | 精确 / FOC-精确                                                            |
| 免重训代理                                         | 1 次标定批          | $O(bd)$      | 精确(线性)/ 墙内近似                                                           |

Table 4: 估计器成本与保证。”精确”指恢复 A 篇的量;”上/下”指认证的单侧界;”近似”指经验证但无保证。

|    | 可观测                              | 成本          | Stage-A 结果 / Stage-B 检查                                                   |
|----|----------------------------------|-------------|---------------------------------------------------------------------------|
| O1 | 价格 $\lambda_\varepsilon$         | 1 次反传       | 与 (2) 吻合至 $\sim 10^{-13}$ / 落在 $\varepsilon \mathbb{E}[\kappa_\infty]$ 带内 |
| O2 | 有效支持 $k_\varepsilon$             | 1 次反传       | $\in (1, d)$ , 追踪软阈值 / 尺度为 $\sqrt{k_\varepsilon}$ 非 $\sqrt{d}$            |
| O3 | 坍塌残差 (3)                         | 免费(自检)      | $\sim 10^{-6}$ / in-regime 保持小                                            |
| O4 | 认证半径 $\varepsilon_{\text{cert}}$ | 闭式          | 精确 / 匹配经验的随机穿越                                                            |
| O5 | 曲率比                              | SDP 审计      | 括号有效(暴力) / 在代理失效处变宽                                                       |
| O6 | 训练-推理差                           | 1 反传 + 1 探测 | $\leq \varepsilon \mathbb{E}[\kappa_\infty]$ / 由曲率界住                      |

Table 5: 六个 Stage-A 可观测:各自廉价、系于一个 A 篇闭式、并带一个 Stage-B 证伪检查。O5/O6 在线性模型上平凡( $\nabla^2 f \equiv 0$ ),在曲率模型上被填上。

**Stage B（真实网络,协议）。** Stage A 验证数学;Stage B 在真实模型上验证测量,此处刻意规定但未运行(它需要 GPU 训练)。协议及其证伪条件为:

1. 代理精度。在中等规模分类器上,一次反传代理  $\mathbb{E}\|\nabla_x \ell\|_1$  应在小  $\varepsilon$  处于  $\varepsilon \mathbb{E}[\kappa_\infty]$  带内匹配有限差分 PGD 价格。**证伪**当差在 margin-density 窗口外超出曲率界。
2. 有效支持标度。跨稠密/稀疏/低秩特征体制,测得价格因子应按  $\sqrt{k_\varepsilon}$  尺度, $k_\varepsilon$  为梯度 participation ratio。**证伪**当  $k_\varepsilon \ll d$  时价格却按  $\sqrt{d}$  尺度。
3. 曲率墙。代理误差应在  $\kappa_\infty$  括号变宽处增长。**证伪**当代理在曲率大处仍准、或在曲率小处失效。

这三条是核心 Stage-B 验证。第四条可选且探索性检查测试有效秩假设,非核心测量主张所必需:

4. (可选) 有效秩杠杆。小  $r_{\text{eff}}$  的 LoRA 适配模型应在占据条件下显  $k_\varepsilon \approx \Theta(r_{\text{eff}})$ 。**证伪**当  $k_\varepsilon$  无论  $r_{\text{eff}}$  如何都追踪  $d$ 。

库的 PyTorch 适配器(adapters.torch)提供执行本协议所需的 grad\_fn/risk\_fn(含极简 PGD 环),参考脚本 torch\_resnet\_pricing.py 端到端实现完整真实模型 workflow:训练网络、从攻击套件(AutoAttack/RobustBench,PGD 作即插即用后备)获取破损曲线、拟合  $P_{\text{breach}}$ 、用价格计与基于 HVP 的曲率探测定价、并解  $\varepsilon^{**}$ 。它是完整可运行模板——本文未执行(需 GPU/torch),故不报告其任何数字,以保持表 3 的证据层级清洁。




Figure 5:  $\epsilon$ -扫描上的六个低成本 Stage-A 可观测(仪表盘)。O1 价格、O2 有效支持  $k_\epsilon$ 、O3 无量纲坍塌残差( $\sim 10^{-6}$ , 印证标度不变性预测  $\lambda_\epsilon \sigma / \phi(t) = \sqrt{k_\epsilon}$ )、O4 认证半径(虚线)。O5(曲率括号)与 O6(训练-推理差)在此为空,因线性模型有  $\nabla^2 f \equiv 0$ ; 它们在 § 7 的已训练 MLP 上被填上。

## 9 库

shadowprice 按上述三层加一个报告层组织:

| 层  | 模块                | 内容                                                           |
|----|-------------------|--------------------------------------------------------------|
| 测量 | price_meter       | $\mathbb{E} \ \nabla_x \ell\ _1$ 代理、有限差分价格、 $\delta^{-3}$ 预算 |
|    | kappa_infty       | SDP + 无依赖上界、随机符号下界                                           |
|    | effective_support | $k_\epsilon$ 诊断、训练期追踪器                                       |
|    | proxy             | 免重训外推 + 测量墙                                                  |
| 决策 | radius            | $\epsilon_{\text{cert}}$ 、 $\epsilon^{**}$ 求解器、比较静态          |
| 控制 | controller        | 闭环预算控制器(比例 / 阻尼-Newton)                                      |
| 报告 | diagnostics       | 六个 Stage-A 可观测 + 仪表盘                                         |
| 适配 | adapters.torch    | PyTorch grad_fn/risk_fn(可选, 惰性导入)                            |

核心无重依赖:cvxpy 可选(仅最紧曲率界需要),torch 可选(仅适配器)。一个最小会话:

```
import shadowprice as sp
k = sp.participation_ratio(grad_x) # effective dimension in [1, d]
out = sp.price_gradnorm(grad_fn, X) # one-pass price + bootstrap CI
br = sp.kappa_infty(H) # curvature bracket {lower, upper}
ec = sp.cert_radius(w, mu) # certification radius
res = sp.optimal_radius(price_fn, Pbreach, K, eps_max=ec) # res.eps_star
ctl = sp.BudgetController(price_fn, marginal_benefit, eps_max=ec)
eps_star = ctl.run(eps0=0.1).eps_star # closed-loop to eps**
```

**设计原则。** 三个选择使工具箱可用且可信。框架无关核心:每个估计器接受普通可调用对象,故同一份代码可为 numpy 玩具、PyTorch 分类器或 JAX 模型定价;框架仅经一个薄适配器进入。可选重依赖:导入路径不需 cvxpy 或 torch——曲率界优雅退化到无依赖公式,适配器惰性导入——故库可在极简环境安装运行,这对一个应易于嵌入现有栈的诊断工具很重要。对闭式验证、且运行时自检:每件仪表都对一个 A 篇闭式做单元测试(13/13 套件),无量纲坍塌残差给用户一个运行时自检,故误测跳一个可见的闸,而非悄悄污染预算。库刻意做得小:它是一件测量仪器,而非训练框架。

**工件与可复现性。** 工具箱以 Apache-2.0 许可在 <https://github.com/<anon>/shadowprice> 开源发布(评审期匿名)。安装为 `pip install shadowprice`(核心:numpy、scipy),可选附加 `[sdp]`(cvxpy,最紧曲率界)、`[torch]`(PyTorch 适配器)、`[plots]`。测试套件(pytest)对 A 篇闭式运行表 7 的 13 项检查;脚本 `demo_instrument_panel.py`、`demo_control_diagnostics.py`、`demo_mlp_training.py` 与 `benchmark.py` 确定性地重生图 1-6(全部固定种子、CPU、版本钉在 README)。Stage-B 参考 `torch_resnet_pricing.py` 是完整可运行模板,需 PyTorch,未在论文构建中执行;无任何报告数字依赖它。

## 10 相关工作与局限

**鲁棒性工具。** 现有开源工具——攻击库与基准,如 Foolbox (Rauber et al., 2017)、AutoAttack (Croce and Hein, 2020)、RobustBench (Croce et al., 2021),建立于 FGSM/PGD (Goodfellow et al., 2015; Madry et al., 2018)——以攻击与评测回答”这个模型有多鲁棒?”。它们不定价鲁棒性:无一读出边际成本  $\lambda_\epsilon$ 、其定价单元  $k_\epsilon$ 、或最优预算  $\epsilon^{**}$ 。shadowprice 与之互补——是一个测量与决策层,而非攻击或基准。

**认证鲁棒性。** 认证方法如随机平滑 (Cohen et al., 2019) 产生逐输入的认证半径;我们的  $\epsilon_{\text{cert}}$  是二元信道约化下的粗粒 population 类比,而  $\epsilon^{**}$  加上了认证本身不涉及的经济层(值得买多少认证半径)。

**局限。** (i) 此处所有验证都是 Stage A——合成加单个小型已训练模型——非大规模深网;Stage B 已规定但未执行。(ii) 深网价格是工作点处的局部一阶代理(A 篇),仅在  $\kappa_\infty$  界定的邻域内有效,非全局保证。(iii) 最优半径结果是约化型经济模型: $P_{\text{breach}}$  由部署威胁模型提供,非导出。

**未来工作:有效秩杠杆。** A 篇的条件性  $k_\epsilon = \Theta(r_{\text{eff}})$  提示低秩适配(LoRA/PEFT, Hu et al., 2022)或可把税从  $\sqrt{d}$  降向  $\sqrt{r_{\text{eff}}}$ ;我们不测试它。它可用有效支持诊断证伪——检查 LoRA 适配模型的  $k_\epsilon$  是否追踪  $r_{\text{eff}}$  而非  $d$ ——我们将其列为 Stage-B 假设,而非结果。



|                         | 攻击/评测 | 认证半径 | 价格 $\lambda_\epsilon$ | 预算 $\epsilon^{**}$ |
|-------------------------|-------|------|-----------------------|--------------------|
| Foolbox / AutoAttack    | ✓     |      |                       |                    |
| RobustBench             | ✓     |      |                       |                    |
| 随机平滑                    |       | ✓    |                       |                    |
| <b>shadowprice</b> (本文) |       | (粗)  | ✓                     | ✓                  |

Table 6: 定位 (Rauber et al., 2017; Croce and Hein, 2020; Croce et al., 2021; Cohen et al., 2019)。现有工具攻击、评测或认证;无一读出鲁棒性的边际价、其定价单元  $k_\epsilon$ 、或经济最优预算  $\epsilon^{**}$ 。诸层互补:攻击库回答”这个模型有多鲁棒”,shadowprice 回答”更多鲁棒性花多少、我该买多少”。

## 11 结论

A 篇证明鲁棒边际价存在一个由有效支持  $\sqrt{k_\epsilon}$  设定的地板。本文使该价格可测、可决、可控:一个每批一次反传的价格计、一个曲率预警、一个有效维数诊断、一个带测量墙的免重训外推器、一套  $\epsilon^{**}$  决策演算、以及一个闭环控制器——每件都系于一个闭式,并在合成模型上经验证 (13/13),打包为一个开源、框架无关的库。眼下的下一步是 Stage B:在真实网络上执行 § 8 的证伪协议,库已为此提供接口。若仪表通过该测试,鲁棒性预算就从猜测变成一项工程测量。

### A $\delta^{-3}$ 有限差分预算

有限差分价格计以中心差分  $D_h = (\hat{R}(\epsilon + h) - \hat{R}(\epsilon - h))/(2h)$  估计  $\lambda_\epsilon = R'(\epsilon)$ ,其中  $\hat{R}$  是每次评估方差  $\sigma_R^2/n$  ( $n$  样本)的蒙特卡洛风险估计。两个误差源竞争。**偏差:**由 Taylor 展开  $\mathbb{E}D_h = R'(\epsilon) + \frac{h^2}{6}R'''(\epsilon) + O(h^4)$ ,故偏差为  $\frac{h^2}{6}R'''$ 。**方差:**两次独立评估给  $\text{Var}(D_h) = \frac{2\sigma_R^2/n}{(2h)^2} = \frac{\sigma_R^2}{2nh^2}$ 。于是

$$\text{MSE}(h) = \frac{(R''')^2}{36} h^4 + \frac{\sigma_R^2}{2n h^2}.$$

对  $h$  极小化,  $\frac{d}{dh}\text{MSE} = \frac{(R''')^2}{9}h^3 - \frac{\sigma_R^2}{nh^3} = 0$ ,给方差最优步长

$$h_\star = \left( \frac{9\sigma_R^2}{n(R''')^2} \right)^{1/6} \propto \left( \frac{\sigma_R^2}{n} \right)^{1/6},$$

代回得  $\text{RMSE}(h_\star) = \Theta((R''')^{1/3}(\sigma_R^2/n)^{1/3}) \propto n^{-1/3}$ 。故要达到目标精度  $\delta$  需

$$n \sim \frac{\sigma_R^2(R''')}{\delta^3} = \Theta(\delta^{-3}),$$

即特征性的  $\delta^{-3}$  预算:把目标误差减半要付  $8\times$  样本。这正是 `fd_budget` 返回的,表 7 的检查 9 数值核验  $n \propto \delta^{-3}$  标度。实用教训(仪表 1 的 cookbook)是取决策能容忍的最松  $\delta$ ,而非追求精度。

### B 验证细节与基准

表 7 列举 13 项自动化检查;表 8 与图 6 报告仪表运行时。

| #  | 检查                      | 验证                                                                                  |
|----|-------------------------|-------------------------------------------------------------------------------------|
| 1  | 有效支持极值                  | $k_\varepsilon = 1(\text{localized}), k_\varepsilon = d(\text{delocalized})$        |
| 2  | 软阈值 participation       | $k_\varepsilon$ 匹配闭式 active 集比                                                      |
| 3  | 认证半径                    | $\varepsilon_{\text{cert}} = \langle w, \mu \rangle / \ w\ _1$                      |
| 4  | $\varepsilon^{**}$ 一阶条件 | $K P'_{\text{breach}}(\varepsilon^{**})  = \lambda(\varepsilon^{**})$               |
| 5  | $\varepsilon^{**}$ 角点情形 | 鲁棒性于 0 处过贵时无内部最优                                                                    |
| 6  | $\kappa_\infty$ 括号(暴力)  | 小 $d$ 下 $\text{lower} \leq \text{true} \leq \text{upper}$ ; SDP 比 $\sum  H_{ij} $ 紧 |
| 7  | 价格梯度范数代理                | 已知批上 $\mathbb{E} \ \nabla_x \ell\ _1$                                               |
| 8  | 有限差分价格 vs 闭式            | 与 $(\sqrt{k_\varepsilon}/\sigma)\phi(t)$ 吻合至 $< 10^{-4}$                            |
| 9  | $\delta^{-3}$ 预算标度      | $n_{\text{req}} \propto \delta^{-3}$ (附录 A)                                         |
| 10 | 控制器收敛                   | 从两侧到达求解器 $\varepsilon^{**}$                                                         |
| 11 | 免重训代理                   | 墙内重现重训价格 ( $< 10^{-6}$ )                                                            |
| 12 | 坍塌残差(标度不变性)             | $\lambda_\varepsilon \sigma / p_S(t) = \sqrt{k_\varepsilon}$ 至 $\sim 10^{-6}$       |
| 13 | 控制器噪声鲁棒性                | 在至多 30% 注入价格噪声下收敛于 $\varepsilon^{**}$ 附近                                            |

Table 7: 13 项自动化 Stage-A 检查, 每项对一个 A 篇闭式。

| $d$  | partic. ratio | price (boot) | $\kappa_\infty$ abs | $\kappa_\infty$ lower | $\kappa_\infty$ SDP |
|------|---------------|--------------|---------------------|-----------------------|---------------------|
| 10   | 0.03 ms       | 2.9 ms       | 0.005 ms            | 0.6 ms                | 35 ms               |
| 100  | 0.06 ms       | 2.8 ms       | 0.02 ms             | 12 ms                 | 1.1 s               |
| 200  | 0.09 ms       | 2.9 ms       | 0.09 ms             | 43 ms                 | 5.6 s               |
| 1000 | 0.61 ms       | 3.1 ms       | 12 ms               | 1.2 s                 | —                   |

Table 8: 每次调用实测墙钟(批 256, 5 次中位)。SDP 曲率界主导, 供定期审计; 其余仪表皆毫秒级。完整曲线见图 6。




Figure 6: 仪表运行时对维数  $d$  (对数-对数, 批 256)。梯度类仪表、有效支持与  $\varepsilon^{**}$  求解全程毫秒级; 廉价曲率界  $O(d^2)$ ; 唯 SDP 界昂贵 ( $O(d^3)$ ), 与其作为审计而非连续监视器的角色一致。

## 参考文献

- Jeremy Cohen, Elan Rosenfeld, and J. Zico Kolter. Certified adversarial robustness via randomized smoothing. In International Conference on Machine Learning (ICML), volume 97 of PMLR, pages 1310–1320, 2019.
- Companion paper (Paper A). The effective-support floor of the adversarial shadow price: An  $\omega(\sqrt{k_\varepsilon})$  lower bound. Companion manuscript, 2025.
- Francesco Croce and Matthias Hein. Reliable evaluation of adversarial robustness with an ensemble of diverse parameter-free attacks. In International Conference on Machine Learning (ICML), volume 119 of PMLR, pages 2206–2216, 2020.
- Francesco Croce, Maksym Andriushchenko, Vikash Sehwal, Edoardo Debenedetti, Nicolas Flammarion, Mung Chiang, Prateek Mittal, and Matthias Hein. RobustBench: a standardized adversarial robustness benchmark. In NeurIPS Datasets and Benchmarks Track, 2021.
- Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples. In International Conference on Learning Representations (ICLR), 2015.
- Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In International Conference on Learning Representations (ICLR), 2022.
- Aleksander Madry, Aleksandar Makelov, Ludwig Schmidt, Dimitris Tsipras, and Adrian Vladu. Towards deep learning models resistant to adversarial attacks. In International Conference on Learning Representations (ICLR), 2018.
- Jonas Rauber, Wieland Brendel, and Matthias Bethge. Foolbox: A python toolbox to benchmark the robustness of machine learning models. arXiv preprint arXiv:1707.04131, 2017.